Vollautomatische Kalibrierungsmethode hochauflösender Satellitenbildzeitreihen mittels europaweiten MODIS Zeitreihen

Paul J. Arzberger

10. Oktober 2026

Inhaltsverzeichnis

1 Motivation und Hauptfragestellung **5**

2 State of the Art **7**

2.1 Filterung verrauschter Satellitenbildzeitreihen 7

2.1.1 Savitzky Golay 7

2.1.1.1 Einführung und grundlegendes Konzept . . . 7

2.1.1.2 Mathematische Funktionsweise 8

2.1.1.3 Iterative Anwendung und obere Hüllkurve (Upper Envelope) 8

2.1.1.4 Adaptive Savitzky-Golay-Filterung 9

2.1.1.5 Vor- und Nachteile 9

2.1.1.6 S-G in der praktischen Anwendung 10

2.1.2 Asymmetrische Gauss'scher Fit 10

2.1.2.0.1 Einführung und grundlegendes Konzept 10

2.1.2.0.2 Mathematische Funktionsweise . . . 10

2.1.2.0.3 Kurvenanpassung und globale Modellierung 12

2.1.2.0.4 Vor- und Nachteile 12

2.1.3 Doppel-Logistische Funktion 12

2.1.3.0.1 Einführung und grundlegendes Konzept 12

2.1.3.0.2 Mathematische Funktionsweise . . . 13

2.1.3.0.3 Kurvenanpassung und globale Modellierung 13

2.1.3.0.4 Vor- und Nachteile 14

2.1.4 Harmonische Analyse und Fourier-Transformation . . 15

2.1.4.0.1 Einführung und grundlegendes Konzept 15

2.1.4.0.2 Mathematische Funktionsweise . . . 16
2.1.4.0.3 Nicht-klassische harmonische Analyse 16
2.1.4.0.4 Kurvenanpassung und globale Modellierung . . . 17
2.1.4.0.5 Vor- und Nachteile . . . 17
2.1.5 Vergleich unterschiedlicher Fittingmethoden anhand verrauschter Satellitendatenzeitreihen aus der Literatur 17
2.1.5.0.1 Rahmenbedingungen und Untersuchungsgebiet . . . 18
2.1.5.0.2 Parametrisierung und Skalierbarkeit 18
2.1.5.0.3 Leistung der Asymmetrischen Gauß- (AG) und Doppel-Logistischen (DL) Modelle . . . 18
2.1.5.0.4 Leistung der Fourier-Analyse (DFT / HANTS) . . . 19
2.1.5.0.5 Savitzky-Golay (SG) und Whittaker Filter . . . 19
2.1.5.0.6 Auswirkungen auf die Phänologie-Bestimmung (Onset of Greenness) . 19
2.1.5.0.7 Fazit . . . 20
2.2 Kalibrierung . . . 23
2.2.1 Radiometrische Bildkalibrierung . . . 23
2.2.2 Absolute Kalibrierung . . . 23
2.2.2.1 Pseudo Invariante Feature Sites - PICS . . . 23
2.2.3 Relative Kalibrierung . . . 24
2.2.3.1 6S-Modell . . . 29
Absorptions- und Streuungseffekte . . . 29
2.2.3.2 Bidirektionale Reflektionsverteilunsgfunktion 32
2.2.3.3 MODIS (Collection V5) BRDF/albedo product . . . 33
2.2.4 Relative Kalibrierung . . . 35
2.2.4.1 Lineare Regression . . . 35
2.2.4.2 PIF's . . . 35
2.3 Bestehende Software . . . 35
2.3.1 LEDAPS - Landsat Ecosystem Disturbance Adaptive Processing System . . . 35
2.3.2 TIMESAT . . . 38

3 Datengrundlagen **40**
3.1 Landsat - Allgemeine Informationen zum Sensor und Trägersystem 40
3.2 Landsat 41
3.3 MODIS - Allgemeine Informationen zum Sensor und Trägersystem 42
3.3.1 MODIS - Compositemethoden 43
3.3.1.1 Maximum Value Composite 43
3.3.2 Datenakquisition - v5 44
3.3.3 Datenakquisition - MODIS Zeitreihe V6 45
3.3.3.1 MODIS Data General Describtion 45
3.3.3.2 MCD43A4 NBAR Data 45
3.3.3.3 MCD43A2 Quality Product 46
3.4 Sentinel 49
3.5 Sinusodial Referenzsystem 49
3.6 UTM-Referenzsystem 50

4 Methodik **51**
4.1 mathematische Grundlagen 51
4.1.1 statistische Kennzahlen 51
4.1.2 Lineare Regression 51
4.1.2.1 OLS - das klassische lineare Modell 51
4.1.3 Harmonische Schwingungen - Fourier Analyse 53
4.1.3.1 Harmonische Schwingungen , Diskrete Fourier Transformation und Analyse 53
4.1.3.2 Rekonstruktion mittels FFT 56
4.1.4 Anwendung Savitzky-Golay Filterung 57
4.1.4.1 Polynom 2. Grades 57
4.1.4.2 Gapfilling 59
4.1.4.3 Verspeicherung der Zeitreihe 60
4.1.5 Ausreisserdetektion 60
4.2 Verwendete Sprachen und Programme aus dem Bereich Data Science sowie Geoinformatik 61
4.2.1 Softwareentwicklung mit Python 61
4.2.1.1 Python 3.8 61
4.2.1.2 Python 3.8 - Multiprocessing 62
4.2.1.3 Python 2.7 62
4.2.1.4 Anaconda 62
4.2.2 ArcGIS, QGIS 63
4.2.3 Betriebsysteme, Speicherplatz und Rechenlogistik . . . 63

5 Durchführung **64**
5.1 Rekonstruktion und Filtern der Verrauschten MODIS V6 Zeitreihe 64
5.1.1 Savitzky-Golay Filterung mit einem Polynom 2. Grades 68
5.1.2 DFT 77
5.1.3 FFT 77

6 Literaturverzeichnis **78**

Kapitel 1

Motivation und Hauptfragestellung

Atmosphärische Einflüsse stellen eine große Herausforderung in Umweltmonitoring mittels Fernerkundung dar. Oft ist es der Fall, dass für ein zu untersuchendes Gebiet, mehrere, sich überlappende Szenen verwendet werden müssen. Im Idealfall sind diese alle vom gleichen Zeitpunkt, wolkenlos und spektral sich sehr ähnlich. Da es aber sehr selten vorkommt, dass einem Analyst all diese Wünsche erfüllt werden, müssen oft Daten verwendet werden, die zeitliche als auch radiometrische Unterschiede zueinander aufweisen. Um die radiometrischen Einflüsse zweier zeitlich versetzter Satellitenbildszenen zu minimieren bedient man sich unterschiedlicher Kalibrierungsmethoden. Absolute als auch relative Kalibrierungsmethoden sind in der Praxis bekannt und werden auch in dieser Arbeit kurz umrissen. Diese Arbeit setzt sich ebenfalls mit einer relativen Kalibrierungsmethodik zwischen MODIS Daten und hochauflösender LANDSAT 5 und 7 Satellitenbilddaten auseinander. Das MODIS (Moderate Resolution Imaging Spectrometer) Satellitensystem liefert seit Jahren, gar schon Jahrzehnten, anhand deren zweier Satelliten Terra und Aqua Aufnahmen des gesamten Planeten. Diese Daten sind anhand einer Bidirektionalen Verteilungsfunktion radiometrisch bereits kalibriert und beinhalten die Oberflächenreflexionen der Erdoberfläche in den gezeigten Ausschnitten. 3 Hauptfragestellungen sollen nun in dieser Arbeit zur relativen Kalibrierung zwischen MODIS und Landsat um rissen werden:

1. Anhand der bereits erwähnten Datengrundlage werden Landsat 5 und 7 relative zu den MODIS-Daten kalibriert und deren Digital Numbers (DN) in Reflexionswerte der Oberfläche transformiert. Im Überlappungsbereich

der Landsatszenen sollten nach der relativen Kalibration radiometrische Werte und Bedingungen herrschen, die eine neuerliche relative Kalibration der Landsatszenen untereinander in einem klaren linearen Zusammenhang sehen und setzen. Eine lineare Regression der Daten im Überlappungsbereich sollte daher eine Steigung von ca 45 Grad aufweise, welches die ideale Kalibration bedeuten würde. Die zeitliche Auflösung der MODIS Szenen zueinander beträgt 8 Tage, und bietet daher eine gute Dichte an Zeitpunkten um diese Kalibration der Landsat-Daten zeitnahe durchführen zu können.

2. Da die MODIS-Daten allerdings in ihren Ausschnitten Datenlücken oder auch Störungen beinhalten, müssen diese zuerst gefiltert oder rekonstruiert werden, damit die Landsat-Daten eine lückenlose, hochqualitative Zeitreihe zur Kalibrierung vorliegen haben. Die Filterung, um das Rauschen in den MODIS Daten zu beseitigen, wird anhand einer FFT, einer DFT und einer Savitzky Golay Filterung durchgeführt. Da diese Filterungen auch unterschiedlich auf das Datenmaterial oder Datenlücken reagieren, werden auch bei der relativen Kalibrierung abweichende Ergebnisse erwartet.

3. Die relativ kalibrierten Landsat-Daten werden hinsichtlich ihres Ergebnisses auch mittels der Software LEDAPS absolut kalibrierten Daten der NASA verglichen um eine weitere Evaluierung bei der Hand zu haben.

Ziel dieser Arbeit ist vor allem die aufgestellten Thesen mit Ergebnissen zu überprüfen und zu bewerten. Auch die Erkenntnis, dass diese Methodik kein geeignetes Mittel ist MODIS Daten mit Landsat-Daten zu relativ zu kalibrieren, kann ein Ergebnis dieser Untersuchung sein.

Kapitel 2

State of the Art

2.1 Filterung verrauschter Satellitenbildzeitreihen

Satellitenbilddaten können durch atmosphärische Einflüsse wie Dunst, nicht identifizierte Wolkenpixel, Aerosole, gasförmigen Dämpfern etc zusätzlich zu den Effekten des Einfallswinkel und der Illumination verfälscht sein. In den meisten Studien über Phänologie sowie der Bestimmung von phenologischen Parametern basierend auf Satellitenbilddaten wird als erster Schritt die verrauschte Zeitreihe in eine gefittete Zeitreihe übergeführt.

2.1.1 Savitzky Golay

2.1.1.1 Einführung und grundlegendes Konzept

Der Savitzky-Golay-Filter (häufig auch als S-G-Filter oder Least-Squares-Filter bezeichnet) ist ein digitaler Tiefpassfilter, der primär zur Glättung von verrauschten Datenreihen eingesetzt wird (Numerical Recipes, 1992, S. 650). Die Grundprämisse der Datenglättung ist, dass eine sich langsam verändernde Variable von zufälligem Rauschen überlagert wird. Während ein einfacher gleitender Durchschnitt (Moving Window Average) das Rauschen zwar reduziert, führt er jedoch bei Merkmalen mit einer von null abweichenden zweiten Ableitung – wie lokalen Maxima oder Signalspitzen – zu systematischen Fehlern: Die Höhe von Spitzen wird verringert und ihre Breite vergrößert, wodurch das zweite Moment (die Linienbreite) der Daten verletzt wird (Numerical Recipes, 1992, S. 650).

Um dieses Problem zu lösen, nähert die Savitzky-Golay-Filterung die Daten innerhalb eines gleitenden Fensters nicht durch eine Konstante an, sondern passt ein Polynom höheren Grades (wie das in Gleichung 1 gezeigte)

mithilfe der Methode der kleinsten Quadrate an die Punkte an (Numerical Recipes, 1992, S. 650).

2.1.1.2 Mathematische Funktionsweise

Der Filter berechnet einen Least-Squares-Fit, um das Polynom an die Datenpunkte innerhalb eines gleitenden Fensters der Breite $N = 2m + 1$ anzupassen. Da dieser Anpassungsprozess lediglich auf einer linearen Matrixinversion basiert, sind die Koeffizienten des angepassten Polynoms lineare Kombinationen der Datenwerte. Dies bedeutet, dass die Filterkoeffizienten im Voraus berechnet werden können (Numerical Recipes, 1992, S. 651). Die eigentliche Glättung eines Datenpunktes Y_j^* erfolgt im laufenden Betrieb äußerst effizient als einfache lineare Faltung (Convolution) der benachbarten Originalwerte Y_{j+i} mit den festen Koeffizienten C_i:

$$Y_j^* = \frac{\sum_{i=-m}^{m} C_i Y_{j+i}}{N} \tag{2.1}$$

Hierbei ist N die Gesamtanzahl der Datenpunkte im Fenster und m die halbe Fensterbreite (Chen et al., 2004, S. 333).

2.1.1.3 Iterative Anwendung und obere Hüllkurve (Upper Envelope)

In der Fernerkundung, speziell bei der Analyse von Vegetationszeitreihen (z.B. NDVI), wird der S-G-Filter häufig modifiziert angewandt. Wolken, Schatten oder schlechte atmosphärische Bedingungen senken die NDVI-Werte in der Regel unnatürlich stark ab (Chen et al., 2004, S. 334). Daher zielt die Filterung darauf ab, die Kurve an die obere Hüllkurve (Upper Envelope) der Daten anzupassen (Eklundh & Jönsson, 2015, S. 16).

Ein gängiger iterativer Ansatz berechnet hierfür zunächst einen langfristigen Trend. Punkte, die unterhalb dieses Trends liegen, werden als Rauschen betrachtet und in Folgeschritten mit geringeren Gewichten W_i versehen (Chen et al., 2004, S. 336). Um die Qualität der iterativen Anpassung in jedem Durchlauf zu bewerten, wird ein Anpassungs-Index (Fitting-Effect Index) F_k berechnet:

$$F_k = \sum_{i=1}^{n} \left(\left| N_i^{k+1} - N_i^0 \right| \cdot W_i \right) \tag{2.2}$$

Dabei ist N_i^{k+1} der gefilterte Wert der k-ten Iteration und N_i^0 der ursprüngliche Wert der Zeitreihe. Der Prozess wird iterativ wiederholt, bis F_k

sein Minimum erreicht hat, was die beste Rekonstruktion des tatsächlichen Vegetationszyklus darstellt (Chen et al., 2004, S. 336).

2.1.1.4 Adaptive Savitzky-Golay-Filterung

Wie in der obigen Abbildung dargestellt, nutzen Auswertungsprogramme wie TIMESAT eine adaptive Version des S-G-Filters (Eklundh & Jönsson, 2015, S. 17). Die Filterung wird zunächst mit einer global definierten Fensterbreite durchgeführt. Werden danach in den gefilterten Daten jedoch starke Anstiege oder Abfälle registriert (etwa durch ein plötzliches Ergrünen der Vegetation im Frühjahr), wird die Fenstergröße lokal verkleinert, was es der Funktion ermöglicht, komplexem Verhalten deutlich genauer zu folgen (Eklundh & Jönsson, 2015, S. 17).

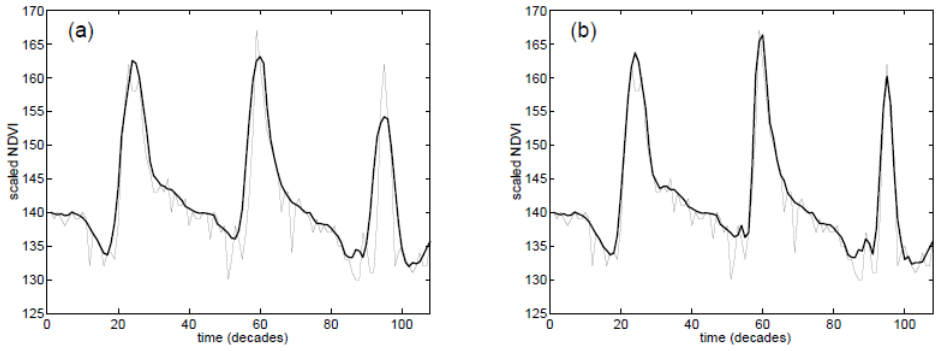


Abbildung 2.1: *Gefittete Funktion nach Savitzky Golay. Die dünne Linie repräsentiert die Rohdaten, die dicke Linie repräsentiert die gefittete Funktion. In (a) ist die Moving-Window-Größe n=5, in (b) ist die Moving-Window-Größe n=3 (Eklundh & Jönsson, 2015, S. 18)*

2.1.1.5 Vor- und Nachteile

Ein entscheidender Vorteil des S-G-Filters ist seine Fähigkeit, subtile und schnelle phänologische Veränderungen in Zeitserien sehr gut zu erfassen (Gao et al., 2008, S. 60). Verglichen mit klassischen Durchschnittsfiltern bleiben bei einem optimal konfigurierten Filter die Höhe, Breite und Fläche von Signalamplituden (Peaks) spektakulär gut erhalten (Numerical Recipes, 1992, S. 653). Da die Umsetzung im Code nur vorberechnete Koeffizienten benötigt, ist sie zudem rechnerisch sehr schnell (Chen et al., 2004, S. 343).

Zu den Nachteilen gehört die hohe Sensibilität gegenüber starkem Rauschen, was bei nicht vollständig entfernten Störungen zu Oszillationen oder systematischen Überschätzungen (Bias) führen kann (Lu et al., 2007, S. 1131). Zudem erfordert die Methode mathematisch zwingend äquidistante Datenpunkte (Numerical Recipes, 1992, S. 650) und führt an den Start- und Endpunkten einer Zeitreihe zu sogenannten Randeffekten (Edge Effects), da dort für das Filterfenster keine realen benachbarten Punkte mehr vorliegen (Chen et al., 2004, S. 337).

2.1.1.6 S-G in der praktischen Anwendung

Das dem Savitzky-Golay-Filter zugrunde liegende Polynom im praktischen Teil der Diplomarbeit wurde mit einem Polynom zweiter Ordnung angenommen und die Breite des Moving-Windows, sprich die Anzahl der MODIS Szene der zur Berechnung herangezogenen Daten wurde mit 15 Epochen festgelegt. Für die Vollständigkeit wird hier noch die Formel des Polynom 2. Grades angeführt.

$$f(t) = a_0 + a_1 \cdot t + a_2 \cdot t^2 \tag{2.3}$$

2.1.2 Asymmetrische Gauss'scher Fit

2.1.2.0.1 Einführung und grundlegendes Konzept Neben dem Savitzky-Golay-Filter ist die Kurvenanpassung (Fitting) mittels asymmetrischer Gauß-Funktionen eine der zentralen Methoden zur Glättung von Zeitreihen und zur Extraktion von phänologischen Parametern aus Satellitendaten (Eklundh & Jönsson, 2015, S. 18). Während klassische harmonische Analysen (wie die Fourier-Transformation) eine Zeitreihe durch eine globale Summe von Sinus- und Kosinuswellen annähern, verwendet dieser Ansatz lokale Modellfunktionen. Dabei werden spezifische Funktionen an Datenintervalle rund um die saisonalen Maxima (Peaks) und Minima der Zeitreihe angepasst (Eklundh & Jönsson, 2015, S. 18; Hermance et al., 2007, S. 3266). Dies ist besonders vorteilhaft, da Wachstumsphasen (Ergrünen) und Absterbephasen (Seneszenz) in der Vegetation so gut wie nie symmetrisch ablaufen.

2.1.2.0.2 Mathematische Funktionsweise Die lokale Basis-Modellfunktion einer asymmetrischen Gauß-Glocke wird abschnittsweise definiert, sodass die linke und rechte Flanke unabhängig voneinander geformt werden können (Eklundh & Jönsson, 2015, S. 19):

$$g(t; x_1, \ldots, x_5) = \begin{cases} exp\left[-\left(\frac{t-x_1}{x_2}\right)^{x_3}\right] & \text{if } t > x_1 \\ \\ exp\left[-\left(\frac{x_1-t}{x_4}\right)^{x_5}\right] & \text{if } t < x_1 \end{cases} \tag{2.4}$$

t	...	Zeit
x_1	...	Position des Maximums oder Minimums
x_2	...	Breite rechte Seite
x_3	...	Wölbung (Flachheit/Steilheit) rechte Seite
x_4	...	Breite linke Seite
x_5	...	Wölbung (Flachheit/Steilheit) linke Seite

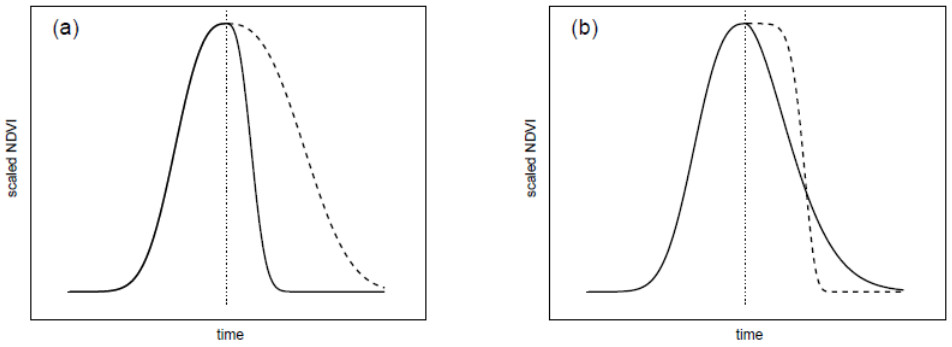


Abbildung 2.2: *Auswirkungen auf die Breite und Wölbung, wenn sich die lokalen Parameter ändern. In (a) wurde x_2 vermindert (durchgezogen) und erhöht (strichliert), was sich in einer geänderten Breite auf der rechten Seite auswirkt. In (b) wurde x_3 vermindert (durchgezogen) und erhöht (strichliert) (Eklundh & Jönsson, 2015, S. 19).*

Die eigentliche Modellfunktion für ein Datenintervall ergibt sich dann durch Hinzufügen der linearen Parameter c_1 und c_2, welche das Basisniveau und die Amplitude des Signals bestimmen (Eklundh & Jönsson, 2015, S. 18):

$$f(t) = c_1 + c_2 \cdot g(t; x) \tag{2.5}$$

2.1.2.0.3 Kurvenanpassung und globale Modellierung Da die Gleichung nicht-linear von den Parametern x abhängt, erfolgt die Optimierung (die Minimierung der Fehlerquadrate) über separable nicht-lineare Least-Squares-Verfahren, wie der Levenberg-Marquardt-Methode (Eklundh & Jönsson, 2015, S. 20). Um das oftmals durch Wolken negativ verzerrte Rauschen auszugleichen, wird die Anpassung in mehreren iterativen Schritten durchgeführt. Punkte, die unter der Kurve liegen, erhalten ein geringeres Gewicht, wodurch sich die Funktion an die obere Hüllkurve (Upper Envelope) der Zeitreihe annähert (Eklundh & Jönsson, 2015, S. 16, 20).

Da die lokalen Funktionen das Signal in den Übergangsbereichen (Flanken und Tälern) oft schlechter beschreiben, werden benachbarte lokale Modellfunktionen mithilfe von sanft abfallenden Cut-off-Funktionen zu einer einzigen, kontinuierlichen globalen Funktion $F(t)$ verschmolzen. Dies verleiht dem Modell die Flexibilität, komplexen Vegetationsverläufen exakt zu folgen (Eklundh & Jönsson, 2015, S. 20-21).

2.1.2.0.4 Vor- und Nachteile Ein entscheidender Vorteil des asymmetrischen Gauß-Fits ist seine Stabilität: Bei extrem stark verrauschten Daten tendieren polynom-basierte Filter (wie Savitzky-Golay) oft zu unerwünschten Schwankungen. In solchen Fällen liefert das Fitting mittels asymmetrischer Gauß-Funktionen oftmals stabilere und physikalisch sinnvollere Ergebnisse (Eklundh & Jönsson, 2015, S. 25). Zudem setzt das mathematische Prinzip nicht zwingend voraus, dass die Datenpunkte in streng gleichmäßigen (äquidistanten) Abständen vorliegen (Hermance et al., 2007, S. 3266).

Ein wesentlicher Nachteil ist hingegen die Rechenintensität: Die numerische Lösung eines nicht-linearen Least-Squares-Problems ist im Vergleich zur einfachen linearen Matrixinversion deutlich rechenaufwendiger (Eklundh & Jönsson, 2015, S. 20). Bei hochkomplexen oder erratischen Zeitreihen ohne klare Saisonalität kann der eingeschränkte Funktionsraum der Gauß-Glocken zudem zu stark vereinfachten, zu glatten Ergebnissen führen (Eklundh & Jönsson, 2015, S. 19, 25).

2.1.3 Doppel-Logistische Funktion

2.1.3.0.1 Einführung und grundlegendes Konzept Neben dem Savitzky-Golay-Filter und der asymmetrischen Gauß-Funktion ist die Kurvenanpassung durch doppel-logistische Funktionen eine weitere etablierte Methode zur Glättung von fehlerbehafteten Satelliten-Zeitreihen und zur Extraktion phänologischer Parameter (Atkinson et al., 2012, S. 401). Ähnlich wie bei

der asymmetrischen Gauß-Funktion basiert dieser Ansatz auf der Verwendung lokaler Modellfunktionen, die gezielt an Datenintervalle rund um die saisonalen Maxima und Minima der Zeitreihe angepasst werden (Eklundh & Jönsson, 2015, S. 18).

2.1.3.0.2 Mathematische Funktionsweise Die lokale Modellfunktion für ein Datenintervall basiert auf einer doppel-logistischen Basisfunktion $g(t; x_1, \ldots, x_4)$, deren Form durch vier nicht-lineare Parameter definiert wird (Atkinson et al., 2012, S. 404; Eklundh & Jönsson, 2015, S. 19):

$$g(t; x_1, \ldots, x_4) = \frac{1}{1 + exp\left(\frac{x_1 - t}{x_2}\right)} - \frac{1}{1 + exp\left(\frac{x_3 - t}{x_4}\right)} \tag{2.6}$$

t	...	Zeit
x_1	...	Position des linken Wendepunkts (stärkster Anstieg)
x_2	...	Änderungsrate (Steilheit) am linken Wendepunkt
x_3	...	Position des rechten Wendepunkts (stärkster Abfall)
x_4	...	Änderungsrate (Steilheit) am rechten Wendepunkt

Um die endgültige Modellfunktion für ein Intervall zu erhalten, wird diese Basisfunktion $g(t; x)$ noch mit den linearen Parametern c_1 (Basisniveau) und c_2 (Amplitude) skaliert: $f(t) = c_1 + c_2 \cdot g(t; x)$ (Eklundh & Jönsson, 2015, S. 18). Um eine physikalisch sinnvolle und glatte Kurvenform zu gewährleisten, werden die Parameterwerte während der mathematischen Anpassung auf ihren zulässigen Bereich restringiert (Eklundh & Jönsson, 2015, S. 19).

2.1.3.0.3 Kurvenanpassung und globale Modellierung Da die Modellfunktion nicht-linear von den Parametern abhängt, erfolgt die Optimierung (Minimierung der Fehlerquadrate) über separable nicht-lineare Least-Squares-Verfahren, wie beispielsweise die Levenberg-Marquardt-Methode (Eklundh & Jönsson, 2015, S. 20).

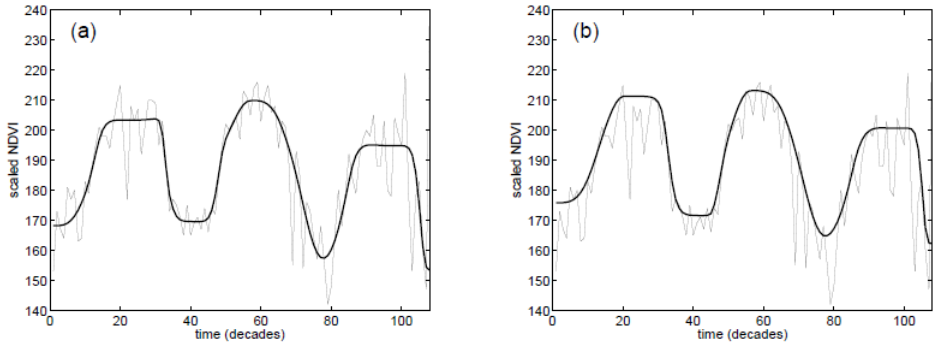


Abbildung 2.3: *Gefittete Funktion nach meheren Iterationen. Die dünne Linie repräsentiert die Rohdaten, die dicke Linie repräsentiert die gefittete Funktion (a). In (b) die erneute Berechnung des Modells mit einer verringerten Gewichtung der niedrigeren Datenwerte (Eklundh & Jönsson, 2015, S. 16).*

Wie in der Abbildung zu sehen, wird das typischerweise negativ verzerrte Rauschen (z. B. durch Wolkenbedeckung) in mehreren iterativen Schritten ausgeglichen (Eklundh & Jönsson, 2015, S. 16). Datenwerte, die unterhalb der ersten angepassten Kurve liegen, erhalten in den Folgeschritten ein stark verringertes Gewicht, wodurch sich die Funktion schrittweise an die obere Hüllkurve (Upper Envelope) der realen Daten annähert (Eklundh & Jönsson, 2015, S. 16). Um die gesamte Zeitreihe lückenlos abzubilden, werden benachbarte lokale Modellfunktionen abschließend mithilfe von sanft abfallenden Cut-off-Funktionen zu einer einzigen kontinuierlichen, globalen Funktion verschmolzen (Atkinson et al., 2012, S. 403; Eklundh & Jönsson, 2015, S. 20-21).

2.1.3.0.4 Vor- und Nachteile Die Methode ist besonders robust gegenüber weißem Rauschen. In Simulationen, bei denen den Zeitreihen künstlich starkes Gaußsches Rauschen hinzugefügt wurde, lieferte sie oft stabilere Ergebnisse als Fourier- oder Savitzky-Golay-Ansätze (Atkinson et al., 2012, S. 416). Bei Vegetationstypen mit nur einer klaren jährlichen Wachstumsphase erzielt die doppel-logistische Funktion exzellente Modellanpassungen und erhält die Flankensteilheit der Signale während der Ergrünungs- und Absterbephasen unverfälscht aufrecht (Atkinson et al., 2012, S. 409, 416).

Ein wesentlicher Nachteil ist, dass die Methode pro definiertem Saisonintervall mathematisch einen einzelnen, klaren Peak erzwingt und dabei Pla-

teaus oder kleinere Fluktuationen an der Spitze ignoriert (Atkinson et al., 2012, S. 409). Bei landwirtschaftlichen Flächen mit mehreren Ernten pro Jahr (Doppel- oder Dreifach-Ernten) liefert sie daher oft unzureichende Ergebnisse (Atkinson et al., 2012, S. 409, 416). Zudem reagiert die Anpassung empfindlich auf starkes Rauschen in den kurzen Übergangsphasen zwischen zwei Wachstumszyklen und kann durch Datentrends, die in das vorherige oder nachfolgende Jahr hineinreichen, verzerrt werden (Atkinson et al., 2012, S. 407, 409).

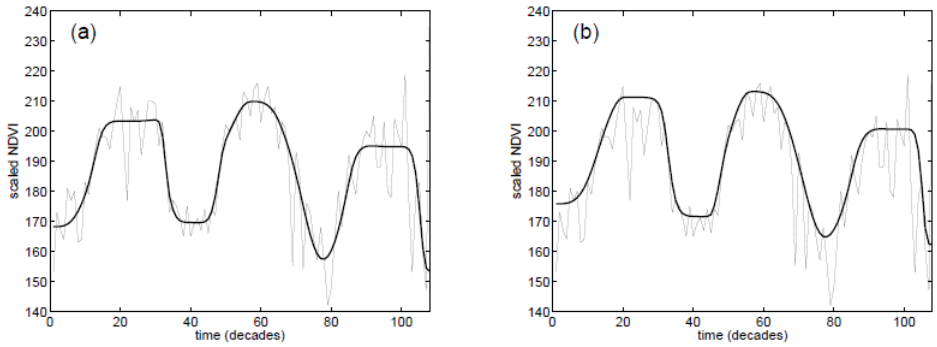


Abbildung 2.4: *Gefittete Funktion nach meheren Iterationen. Die dünne Linie repräsentiert die Rohdaten, die dicke Linie repräsentiert die gefittete Funtion (a). In (b) die erneute Berechnung des Modells mit einer verringerten Gewichtung der niedrigeren Datenwerten (Eklundh & Jönsson, 2012)*

2.1.4 Harmonische Analyse und Fourier-Transformation

2.1.4.0.1 Einführung und grundlegendes Konzept Die harmonische Analyse, zumeist implementiert in Form der Fourier-Transformation, ist eine weit verbreitete, globale Methode zur Glättung von Zeitreihen und zur Extraktion phänologischer Parameter aus Fernerkundungsdaten (Atkinson et al., 2012, S. 401–402). Das Grundprinzip besteht darin, das komplexe, oft verrauschte Vegetationssignal in eine Reihe von Sinus- und Kosinuswellen (Harmonische) mit unterschiedlichen Frequenzen zu zerlegen (Atkinson et al., 2012, S. 402). Hochfrequente Fluktuationen werden dabei als unerwünschtes Rauschen (z. B. durch Wolken oder atmosphärische Störungen) interpretiert und herausgefiltert, während die verbleibenden niederfrequenten Harmonischen die dominante, tatsächliche saisonale Variation der Vegetation repräsentieren (Atkinson et al., 2012, S. 402; Wagenseil & Samimi,

2006).

2.1.4.0.2 Mathematische Funktionsweise In der klassischen diskreten Fourier-Transformation (DFT) wird der Vegetationsindex $VI(t)$ zum Zeitpunkt t in seine Frequenzkomponenten zerlegt. Aus dem Real- und Imaginärteil der Transformation lassen sich die Magnitude (Amplitude) $Fm(n)$ und die Phase $Fp(n)$ für jede Oberschwingung n berechnen. Die geglättete Kurve $VI^*(t)$ wird anschließend durch die Summe eines Basiswerts $Fm(0)$ und einer ausgewählten Anzahl u von Harmonischen rekonstruiert (Atkinson et al., 2012, S. 402):

$$VI^*(t) = Fm(0) + \sum_{n=1}^{u} Fm(n) \cos\left(\frac{2\pi nt}{T} - Fp(n)\right) \tag{2.7}$$

T	...	Länge der Zeitperiode (z.B. Anzahl der Komposite pro Jahr)
u	...	Anzahl der verwendeten Harmonischen (Fourier-Komponenten)
$Fm(n)$	...	Magnitude der n-ten Harmonischen
$Fp(n)$	...	Phase der n-ten Harmonischen

2.1.4.0.3 Nicht-klassische harmonische Analyse Ein Problem der klassischen Fourier-Analyse ist die strikte Voraussetzung, dass die Datenpunkte in absolut gleichmäßigen zeitlichen Abständen (äquidistant) vorliegen müssen (Hermance et al., 2007, S. 3265). Um dies zu umgehen und zeitliche Lücken (Data Gaps) besser zu handhaben, wird in der Praxis häufig eine modifizierte, nicht-klassische harmonische Analyse eingesetzt. Diese löst das Problem mittels der Methode der kleinsten Quadrate (Least-Squares) und kombiniert die harmonische Serie zusätzlich mit einem niedriggradigen Polynom, um langfristige Sensordrifts oder Klimatrends über mehrere Jahre abzubilden (Bradley et al., 2007, S. 140; Hermance et al., 2007, S. 3266):

$$d_{pred}(t_i) = \sum_{k=0}^{L} c_k t_i^k + \sum_{j=1}^{M} \left[a_j \cos\left(\frac{2\pi j}{T} t_i\right) + b_j \sin\left(\frac{2\pi j}{T} t_i\right)\right] \tag{2.8}$$

wobei L der Grad des Polynoms für den Langzeittrend und M die Ordnung der harmonischen Serie ist (Hermance et al., 2007, S. 3266).

2.1.4.0.4 Kurvenanpassung und globale Modellierung Ein wesentlicher Vorteil der Methode ist ihre einfache Parametrisierung, da primär nur die Anzahl der zu verwendenden Harmonischen definiert werden muss (Atkinson et al., 2012, S. 401). Niedrige Frequenzen glätten das Signal stark, können jedoch wichtige Variationen übersehen. Für natürliche Vegetation mit einem klaren Wachstumszyklus pro Jahr (Single Season) ist die Verwendung der ersten 3 bis 4 Fourier-Komponenten meist ideal (Atkinson et al., 2012, S. 404). Um in landwirtschaftlichen Regionen komplexere Muster mit zwei oder drei Ernten pro Jahr abzubilden, müssen typischerweise etwa 6 Komponenten verwendet werden (Atkinson et al., 2012, S. 404).

2.1.4.0.5 Vor- und Nachteile Zu den größten Stärken der Fourier-Analyse zählt die robuste Konstruktion durchschnittlicher, jährlicher Basismodelle (Average Annual Phenologies) bei extrem stark verrauschten Daten (Bradley et al., 2007, S. 140). Im Gegensatz zu asymmetrischen Gauß- oder doppel-logistischen Modellen, die das Signal in eine strikte einzelne Glockenform zwingen, kann die Fourier-Transformation (durch das Hinzufügen weiterer Harmonischer) mühelos Gebiete mit multiplen Wachstumszyklen (Doppel-Ernten) erfassen (Atkinson et al., 2012, S. 409, 416).

Die gravierendsten Nachteile ergeben sich aus der Natur der zugrunde liegenden symmetrischen Sinus- und Kosinusfunktionen. Da das Wachstum und Absterben von Vegetation (Ergrünen und Seneszenz) naturgemäß oft asymmetrisch verläuft, kann der Fourier-Ansatz diese Asymmetrie nur bedingt abbilden und führt häufig zu systematischen Kurvenverschiebungen im Vergleich zu den Originaldaten (Chen et al., 2004, S. 333, 338). Zudem neigt die Fourier-Glättung bei unregelmäßigem Rauschen oder Datenlücken im Winter massiv zur Bildung künstlicher, fehlerhafter Oszillationen (ßpurious oscillationsöder "Ringing-Effekt"), weshalb sie häufig durch zusätzliche Rauigkeits-Dämpfungen (Roughness Damping) künstlich stabilisiert werden muss (Chen et al., 2004, S. 333; Hermance et al., 2007, S. 3266).

2.1.5 Vergleich unterschiedlicher Fittingmethoden anhand verrauschter Satellitendatenzeitreihen aus der Literatur

Atkinson et al. (2012) wenden anhand des MERIS Terrestrial Chlorophyll Index (MTCI), ein Vegetationsindex der linear vom Chlorophyllgehalt in überschirmten Flächen abhängt und aus einer MERIS-Zeitreihe abgeleitet wurde, die Diskrete Fourier Transformation, eine Asymmetrische Gauss Funktion, eine Doppel-Logistische Funktion sowie einen Whittaker Smoother auf ihre MTCI-Zeitreihe an. Generell sei vorweg gesagt, dass jede Me-

thode ihre Vor- und Nachteile mit sich bringt, wie sie auf Messfehler oder Ausreisser reagiert beziehungsweise zur Interpretation herangezogen werden kann (de Beurs & Henebry, 2010).

2.1.5.0.1 Rahmenbedingungen und Untersuchungsgebiet Die Studien von Atkinson et al. (2009) und Atkinson et al. (2012) vergleichen diese Glättungsverfahren (ergänzt um den Savitzky-Golay-Filter) zur Extraktion phänologischer Parameter (Atkinson et al., 2009; Atkinson et al., 2012, S. 401). Als Untersuchungsgebiet diente der indische Subkontinent, der aufgrund seiner extrem heterogenen Landschaften – von tropischen Regenwäldern bis hin zu stark landwirtschaftlich genutzten Zonen mit multiplen Ernten pro Jahr – besonders anspruchsvoll für Modellierungen ist (Atkinson et al., 2009; Atkinson et al., 2012, S. 404). Im Gegensatz zum fehleranfälligen NDVI weist der hier genutzte MTCI ein höheres Signal-Rausch-Verhältnis auf und ist kaum durch atmosphärische Störungen negativ verzerrt (Atkinson et al., 2012, S. 401). Das Rauschen in MTCI-Daten kann daher als weißes (Gaußsches) Rauschen um einen lokalen Mittelwert angenommen werden, weshalb die Modelle an diesen Mittelwert anstatt an die obere Hüllkurve angepasst werden (Atkinson et al., 2012, S. 401).

2.1.5.0.2 Parametrisierung und Skalierbarkeit Eine zentrale Erkenntnis ist, dass es für komplexe, heterogene Gebiete nicht möglich ist, ein einziges, perfektes Set an Parametern für Modelle wie Savitzky-Golay, Asymmetrische Gauß-Funktion oder Doppel-Logistik zu finden (Atkinson et al., 2009; Atkinson et al., 2012, S. 401). Da Parameter wie Fenstergröße, Rausch-Schwellenwerte oder Anpassungsstärke manuell vorgegeben werden müssen, kann dies zu Inkonsistenzen in den abgeleiteten Informationen führen (Atkinson et al., 2012, S. 401).

2.1.5.0.3 Leistung der Asymmetrischen Gauß- (AG) und Doppel-Logistischen (DL) Modelle Lokale Anpassungsverfahren wie AG und DL zeichnen sich dadurch aus, dass sie die Flankensteilheit der phänologischen Signale beim Ergrünen und Absterben extrem gut und unverfälscht erhalten (Atkinson et al., 2012, S. 409). In Simulationen mit starkem, künstlichem weißem Rauschen lieferte das DL-Modell im Vergleich zu den anderen Methoden oft die stabilsten Ergebnisse (Atkinson et al., 2012, S. 409, 416). Für natürliche Vegetationsarten mit exakt einer Wachstumsphase erzielen beide Modelle exzellente Anpassungen (Atkinson et al., 2012, S. 416). Der größte Nachteil ist jedoch, dass sie pro Saisonintervall mathematisch exakt einen

Signal-Peak erzwingen (Atkinson et al., 2012, S. 409). In Gebieten mit zwei oder drei Ernten pro Jahr lieferten sie daher unzureichende Ergebnisse und reagierten sehr empfindlich auf Rauschen in den kurzen Übergangsphasen sowie auf Signaltrends aus benachbarten Wachstumszyklen (Atkinson et al., 2012, S. 407, 409).

2.1.5.0.4 Leistung der Fourier-Analyse (DFT / HANTS) Die Fourier-basierte Glättung erwies sich für großflächige, heterogene Räume als eine sehr praxistaugliche und konsistente Methode (Atkinson et al., 2009). Sie ist einfach zu implementieren und benötigt vom Nutzer primär nur die Anzahl der Harmonischen als Parameter (Atkinson et al., 2009; Atkinson et al., 2012, S. 401). Im Gegensatz zu AG und DL kann sie problemlos multiple Erntezyklen abbilden: 3 bis 4 Harmonische reichten für natürliche Vegetation aus, während 6 Harmonische komplexe landwirtschaftliche Doppel- oder Dreifach-Ernten zuverlässig rekonstruierten (Atkinson et al., 2009; Atkinson et al., 2012, S. 404). Ein Schwachpunkt ist, dass die Fourier-Analyse bei unregelmäßigem, negativem Rauschen zur Bildung unerwünschter Oszillationen (Wellenmuster) neigen kann, was jedoch durch die Reduktion auf wenige, niederfrequente Komponenten gedämpft werden kann (Atkinson et al., 2012, S. 409).

2.1.5.0.5 Savitzky-Golay (SG) und Whittaker Filter Der Savitzky-Golay-Filter zeigte bei vollautomatischer Auswertung verschiedenster Vegetationszonen Schwächen, da es unmöglich war, einheitliche Parameter für alle Landschaftstypen zu finden, und konnte qualitativ nicht so überzeugen wie der Fourier-Ansatz (Atkinson et al., 2009). Der Whittaker-Filter lieferte bei realen Datenreihen zwar extrem gute Fehlerwerte (niedrigste RMSE), wurde aber in strengen statistischen Metriken (AIC, BIC) aufgrund seiner vielen freien Modellparameter stark bestraft und reagierte sensibler auf künstliches Rauschen als das DL-Modell (Atkinson et al., 2012, S. 415-416).

2.1.5.0.6 Auswirkungen auf die Phänologie-Bestimmung (Onset of Greenness) Das finale Ziel der Glättung ist die Schätzung phänologischer Parameter wie dem Beginn der Wachstumsphase (Onset of Greenness). Trotz methodischer Unterschiede wichen die Schätzungen in homogenen Waldgebieten modellübergreifend im Durchschnitt nur um etwa eine Woche voneinander ab (Atkinson et al., 2012, S. 416). Die größten Diskrepanzen, mit durchschnittlich 3 bis 4 Wochen, zeigten sich in trockenen Laubwäldern (Atkinson et al., 2012, S. 414, 416). Deren Wachstum ist stark von unre-

gelmäßigen Niederschlägen und lokalen Dürreereignissen abhängig, was zu einer extremen Rauschanfälligkeit und großen inter-annualen Variabilität führt (Atkinson et al., 2012, S. 415, 416).

2.1.5.0.7 Fazit Für die vollautomatische Prozessierung extrem großer, heterogener Gebiete mit natürlichen und komplexen landwirtschaftlichen Rhythmen empfehlen die Autoren die Fourier-Analyse, da diese leicht zu implementieren ist und am verlässlichsten multiple Saisons abbildet (Atkinson et al., 2009; Atkinson et al., 2012, S. 416). Für die formtreue und rauschresistente Rekonstruktion einzelner, reiner Vegetationszyklen (Single Season) ist hingegen das Doppel-Logistische Modell hervorragend geeignet (Atkinson et al., 2012, S. 416).

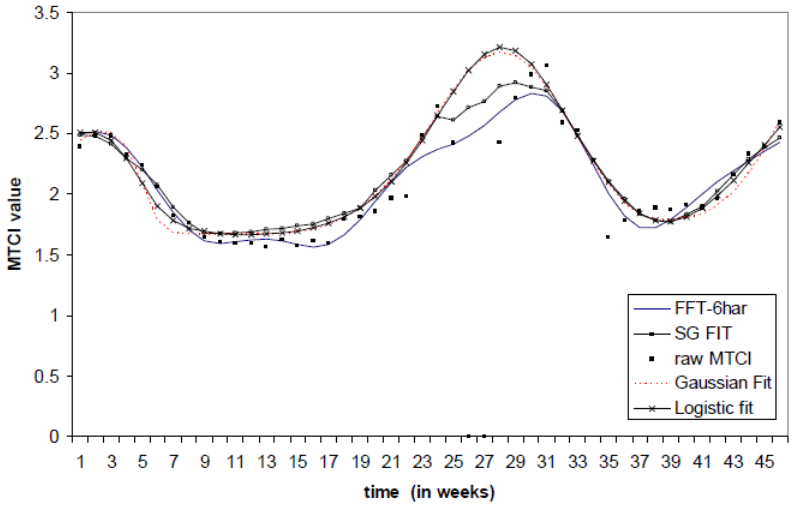


Abbildung 2.5: *Vergleich der Fittingmethoden Savitzky-Golay (SG), Gauss'scher Fit, Logistischer Fit (hier mit TIMESAT) und Fourier (FFT) für eine landwirtschaftlich genutzte Fläche in Indien (Atkins et al.,2009)*

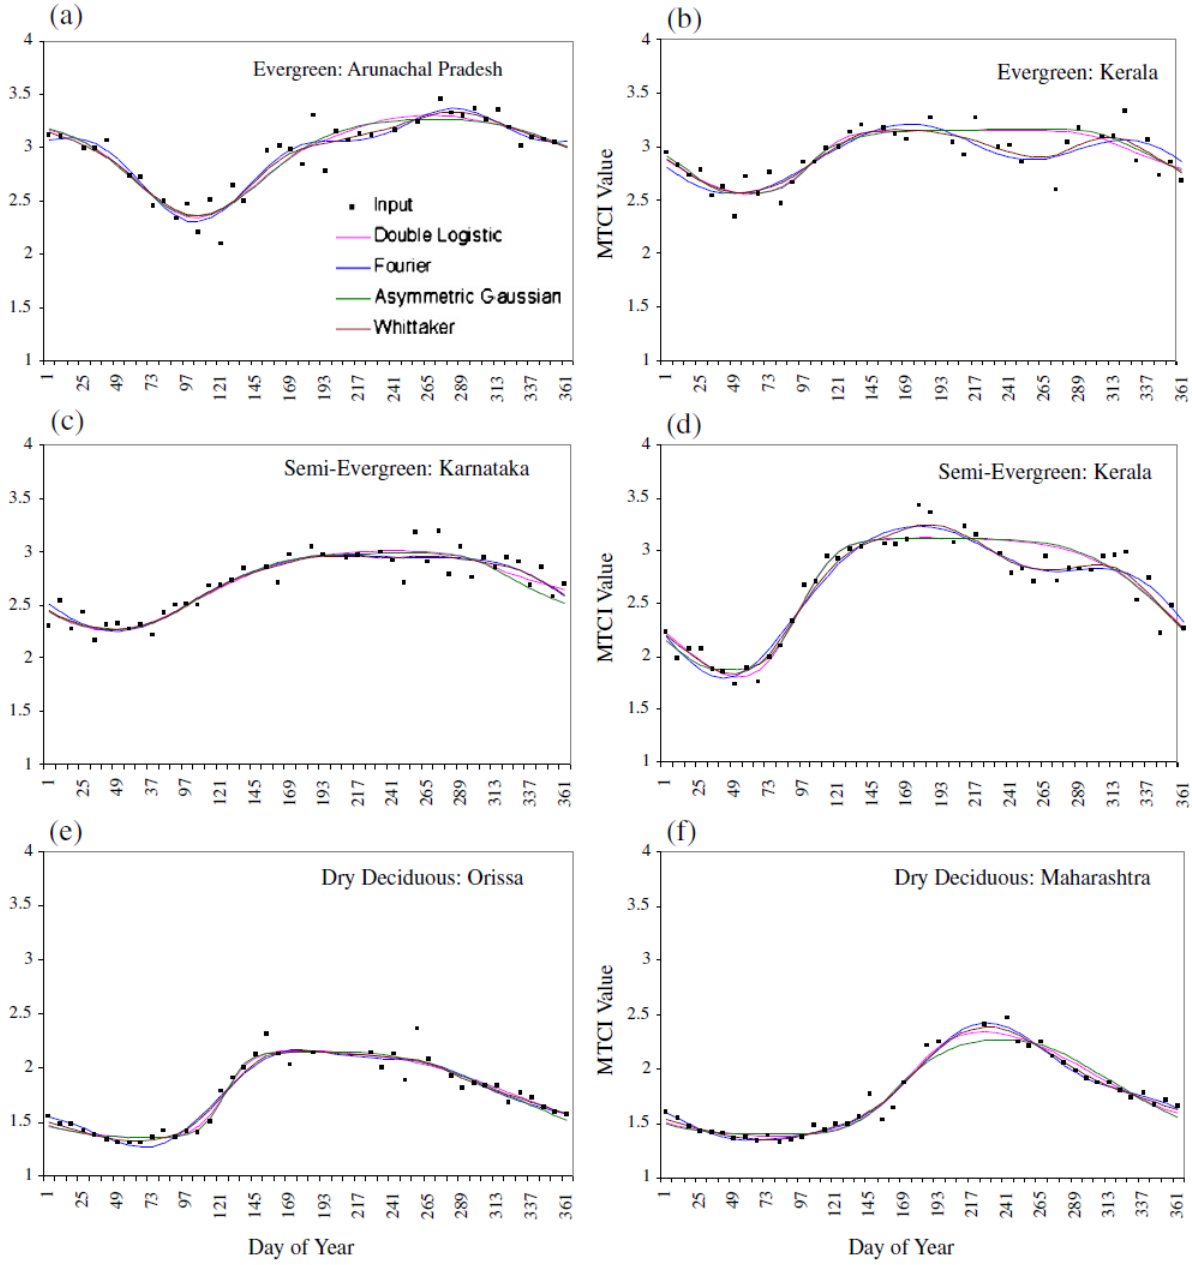


Abbildung 2.6: *Vergleich der Fittingmethoden Savitzky-Golay (SG), Gauss'scher Fit, Logistischer Fit (hier mit TIMESAT) und Fourier (FFT) anhand von immergrünen Flächen (a,b), semi-immergrünen Flächen (c,d), trockene Laubwälder (e,f) (Atkins et al.,2012)*

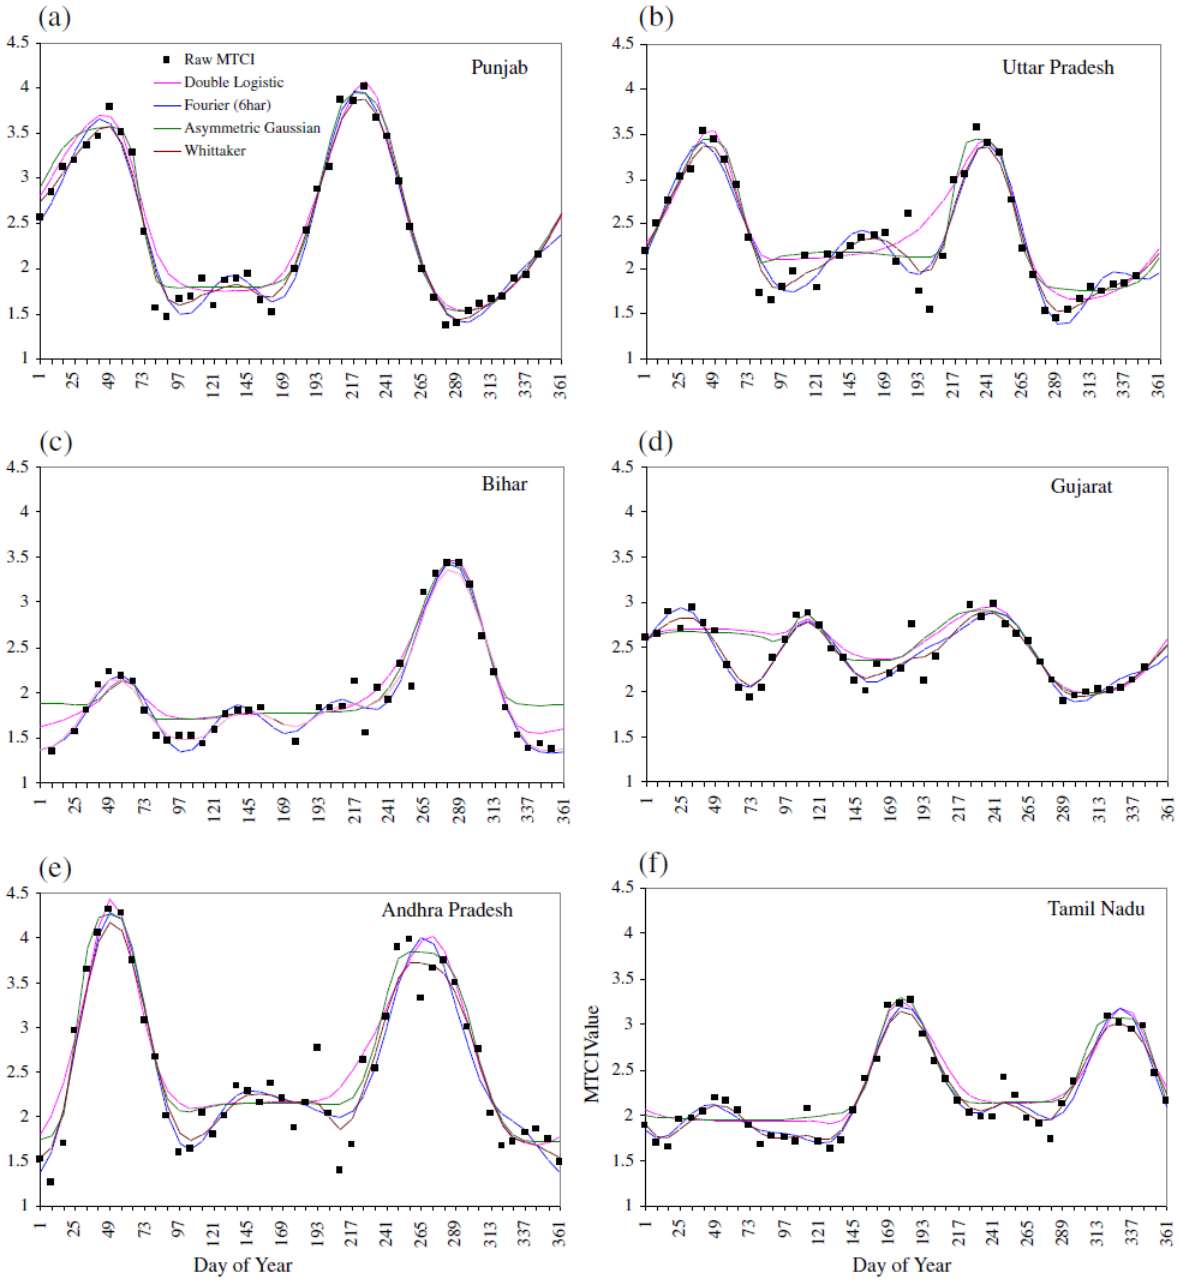


Abbildung 2.7: *Vergleich der Fittingmethoden Savitzky-Golay (SG), Gauss'scher Fit, Logistischer Fit (hier mit TIMESAT) und Fourier (FFT) anhand von landwirtschaftlich genutzten Flächen - Punjab (a), Uttar Pradesh (b), Bihar (c), Gujarat (d), Andhra Pradesh (e), Tamil Nadu (f) (Atkins et al.,2012)*

2.2 Kalibrierung

2.2.1 Radiometrische Bildkalibrierung

Die radiometrische Kalibrierung von Satellitenbildern unterscheidet grundlegend zwischen der **absoluten Kalibrierung** (Atmosphärenkorrektur) und der **relativen Kalibrierung** (TU Graz, 2021, S. 3, 10).

2.2.2 Absolute Kalibrierung

Unter der absoluten radiometrischen Kalibrierung versteht man die Umrechnung von Digital Numbers (DN) eines Satelliten in physikalische Einheiten in „am Sensor“ spektrale Strahlung $\left[Wm^{-2}sr^{-1}\mu m^{-1}\right]$ (Helder et al., 2013, S. 1360; TU Graz, 2021, S. 15). Digital Numbers eines Sensors haben keine Gemeinsamkeiten mit einem anderen Aufnahmesystem (Helder et al., 2013, S. 1360). Die Konvertierung zu „am Sensor“ eintreffender spektraler Information und Top-Of-Atmosphere Reflexion (TOA) sind fundamentale Vorgehensweisen, um die Daten/Produkte zweier unterschiedlicher Sensoren zu vergleichen (Helder et al., 2013, S. 1360).

Der vollständige Verarbeitungs-Workflow der absoluten Kalibrierung gliedert sich in drei zentrale Schritte (TU Graz, 2021, S. 15):

1. Erfassung der einheitslosen Digital Numbers (DN) durch den Sensor.
2. Radiometrische Kalibrierung der DN zur spektralen Strahldichte (*Radiance*).
3. Atmosphärenkorrektur der Strahldichte zur Ermittlung der tatsächlichen Oberflächenreflexion (*Reflectance*).

Zur Atmosphärenkorrektur werden sowohl empirische Ansätze wie die *Dark Object Subtraction* (DOS) als auch physikalische Strahlungstransfermodelle (z. B. LOWTRAN, MODTRAN) oder spezialisierte Software-Tools wie Sen2Cor für Sentinel-2 eingesetzt (TU Graz, 2021, S. 17, 19).

2.2.2.1 Pseudo Invariante Feature Sites - PICS

Es existiert eine Vielzahl an Möglichkeiten von pre-launch laborgetätigten Kalibrationen und post-launch on-orbit Kalibrierungen (Helder et al., 2013, S. 1360). Eine der meistverwendeten on-orbit Kalibrierungsmethoden ist die Verwendung von Pseudo Invarianten Calibration Sites (PICS) (Helder et al., 2013, S. 1360–1361). PICS sind radiometrisch stabile Orte mit dem ursprünglichen Zweck der Überwachung der radiometrischen Stabilität

eines Sensors mit einem hohen Genauigkeitsgrad (Helder et al., 2013, S. 1360–1361). Jene Sites zeigen auch hohes Potenzial, unter ähnlicher Genauigkeit zur absoluten Kalibrierung herangezogen zu werden (5% Genauigkeit bei Kreuzkalibrierung MSS und Landsat 5 TM laut Helder et al., 2013, S. 1361–1362). Die zeitliche Stabilität der Libya 4 - Kalibrierungssite wurde anhand des HYPERION EO-1, einem hyperspektralem Erdbeobachtungssensor in hochtransmittiven Spektren des SWIR (bei 1628 nm Wellenlänge ist die Atmosphäre nahezu transparent) untersucht (Helder et al., 2013, S. 1362–1363).

2.2.3 Relative Kalibrierung

Im Gegensatz zur absoluten Kalibrierung dient die relative radiometrische Kalibrierung der Bereinigung radiometrischer Unterschiede zwischen mehreren Bildaufnahmen (TU Graz, 2021, S. 12). Sie bildet eine essenzielle Vorverarbeitung für die Erstellung nahtloser Bildmosaike sowie für automatische Veränderungsanalysen (*Change Detection*) (TU Graz, 2021, S. 12). Zudem ermöglicht sie vor allem in gebirgigen Regionen mit schwieriger Feldarbeit eine erhebliche Budgeteinsparung, da ermittelte Trainings- und Referenzgebiete für die überwachte Klassifikation auf benachbarte Szenen übertragen werden können (TU Graz, 2021, S. 13–14).

Zu den gängigsten methodischen Ansätzen zählen (TU Graz, 2021, S. 10):

- **Regressionsfunktionen:** Berechnung von Band-Offsets und Gains basierend auf den Grauwertbeziehungen in den Überlappungsbereichen benachbarter Szenen (TU Graz, 2021, S. 20–21).
- **Histogramm-Matching:** Anpassung der kumulativen Verteilungsfunktion der Grauwerte einer Szene an ein Referenzbild (TU Graz, 2021, S. 24). Während regressionsbasierte Verfahren bei Verzerrungen in der Überlappungszone geometrische Probleme verursachen können, arbeitet das Histogramm-Matching unabhängig von geometrischen Verzerrungen (TU Graz, 2021, S. 27).

1. Sonoran Desert – Nordamerika (Helder et al., 2013, S. 1362)
2. Libya 4 – Nordafrika (Helder et al., 2013, S. 1361)
3. Sahara – Nordafrika (Helder et al., 2013, S. 1361)
4. Railroad Valley – Nevada, U.S.A. (Markham et al., 2003, S. 310)

5. Ivanpah Playa – Kalifornien, U.S.A. (Markham et al., 2003, S. 310)

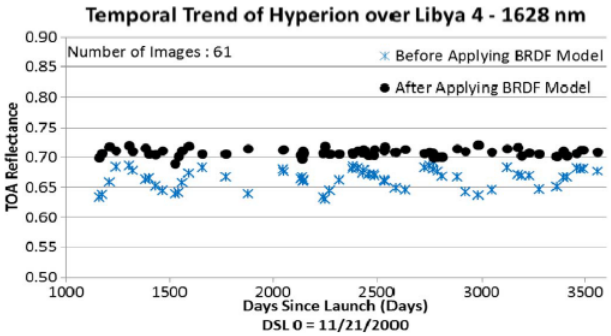


Fig. 3. TOA reflectance temporal trend of hyperion over Libya 4. BRDF was corrrected to a nadir solar zenith angle for ease of viewing.

Abbildung 2.8: *TOA-Reflexion: Zeitlicher Trend von HYPERION über der Libya 4 Testsite vor und nach Korrektur mittels BRDF-Modell (Helder et al., 2013, S. 1363)*

Helder et al. (2013, S. 1364–1365) wenden ein vereinfachtes lineares BRDF-Modell auf die Libya 4 Testsite an. In diesem Modell wird primär der solare Zenitwinkel berücksichtigt:

$$\rho_{\text{Libya4}}(\lambda, \text{SZA}) = k(\lambda) \cdot \rho_h(\lambda) \cdot [a(\lambda) \cdot (\text{SZA}) + 1] \tag{2.9}$$

Die TOA-Reflexion der Libya 4 PICS wird durch ρ_{Libya4} repräsentiert, $k(\lambda)$ ist der Skalierungsfaktor für das Hyperion-Spektrum, $\rho_h(\lambda)$ beschreibt das Hyperion-Referenzspektrum und $a(\lambda)$ repräsentiert den linearen Koeffizienten zur Korrektur des solaren Zenitwinkels (SZA) (Helder et al., 2013, S. 1365). Die modellierten Werte und die tatsächlichen Beobachtungen weisen dabei eine geringe Abweichung (Bias) von lediglich 1,37% auf (Helder et al., 2013, S. 1365).

Um das Modell zu validieren, wurde es auf Landsat 7 ETM+ Daten angewendet (Helder et al., 2013, S. 1366). Da Landsat primär spektrale Strahldichte am Sensor misst, muss diese mittels einer Standardprozedur in die TOA-Reflexion übergeführt werden (Helder et al., 2013, S. 1366):

$$\rho_\lambda = \frac{\pi \cdot L_\lambda \cdot d^2}{ESUN_\lambda \cdot \cos \Theta_s} \tag{2.10}$$

Dabei repräsentiert ρ_λ die planetare TOA-Reflexion [einheitslos], L_λ die spektrale Strahldichte am Sensor $\left[\mathrm{W} \cdot \mathrm{m}^{-2} \cdot \mathrm{sr}^{-1} \cdot \mu\mathrm{m}^{-1}\right]$, d die Erd-Sonnen-Distanz in astronomischen Einheiten (AU), $ESUN_\lambda$ die mittlere exoatmosphärische solare Bestrahlungsstärke $\left[\mathrm{W} \cdot \mathrm{m}^{-2} \cdot \mu\mathrm{m}^{-1}\right]$ und Θ_s den solaren Zenitwinkel (Helder et al., 2013, S. 1366). Die Vergleiche liegen innerhalb der angegebenen Unsicherheiten von 2% für MODIS und 5% für Landsat 7 ETM+ (Helder et al., 2013, S. 1366).

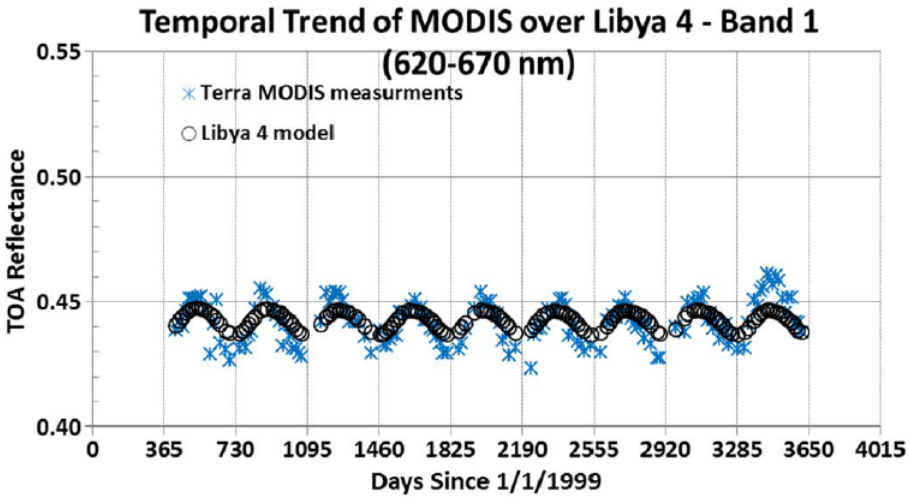


Abbildung 2.9: *Gemessene MODIS und modelierte MODIS mittels linearer BRDF über Libya4 (Helder et al., 2013)*

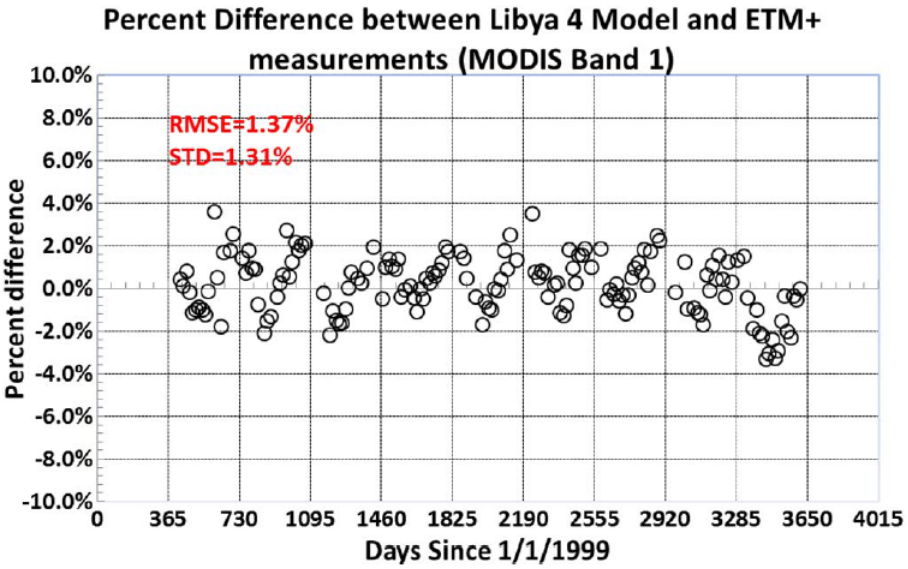


Abbildung 2.10: *Prozent Differenz zwischen MODIS-Beobachtungen und Modellberechnungen (Helder et al., 2013)*

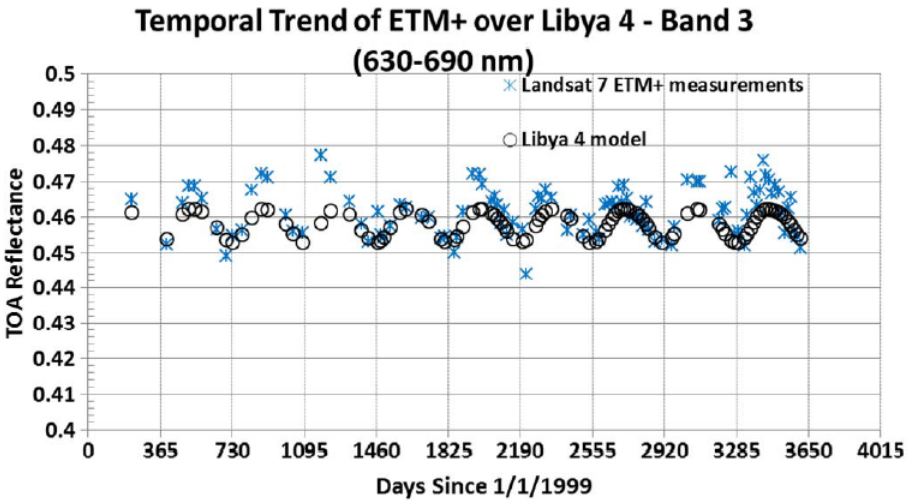


Abbildung 2.11: *Gemessene ETM+ (asteriks) und modelierte Prediktionen (kreis) über Libya4 (Helder et al., 2013)*

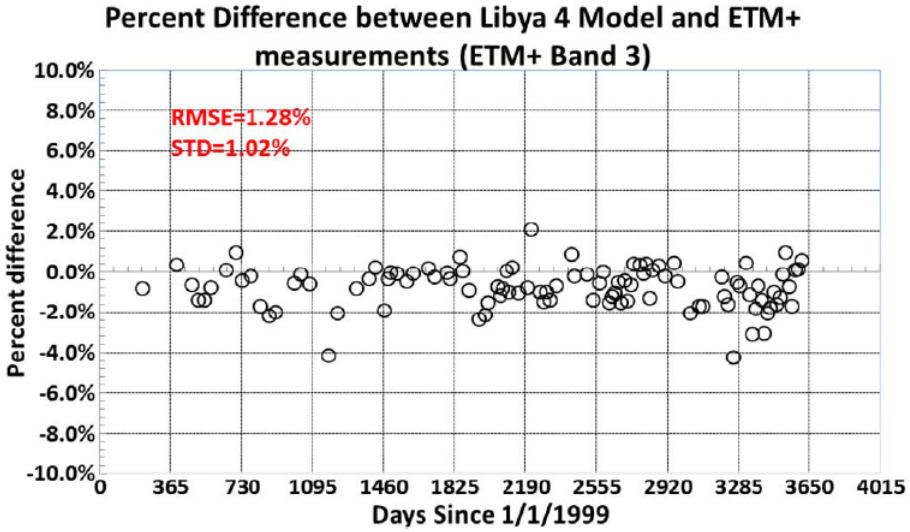


Abbildung 2.12: *Prozent Differenz zwischen ETM+ -Beobachtungen und Modellberechnungen (Helder et al., 2013)*

2.2.3.1 6S-Modell

In diesem Unterabschnitt wird grob die 6S Methode zur Berechnung eines empfangenen Signales beschrieben. Für eine genaue Diskussion wird auf die Literatur von Vermote et al. (2006), „Second Simulation of a Satellite Signal in the Solar Spectrum - Vector (6SV)“ hingtewiesen.

Anhand der 6S (6S - Second Simulation of a Satellite Signal in the Solar Spectrum) radiometrischen Transfer Codes wird der Einfluss der Atmosphäre, speziel die Absorption und Streuung modelliert. Im Idealfall (mit keiner vorhandenen) Atmosphäre wird ein Teil der ausgesandten Photonen von der Erdoberfläche absorbiert und der Rest wieder in den Weltraum zurück reflektiert wird. Diese aufgefangenen Messungen selbst hängen direkt mit der Eigenschaft der Reflexionsoberfläche zusammen.bei vorhandener Erdatmosphäre Circa 80% der Photonen kommen bei einer Wellenlänge von $0.85\mu m$ und 50% bei $0.45\mu m$ an. Jene Lichtteilchen gehen bei zwei Prozessen , der Absorption (durch Gase, hauptsächlich $O_2, O_3, H_2O, CO_2, CH_4$ sowie N_2O und der Streuung verloren. Die Absorption ist in der Regel klein gehalten und man vermeidet in der Fernerkundung Bänder in denen stark absorbiert wird. Die Streuung wird durch nicht absorbierende Moleküle verursacht. Das Photon wird dabei in eine andere Richtung reemmitiert in die es eigentlich weiter gehen sollte. In der Regel durchläuft ein Photon mehrere solche Streuungsvorgänge, welche in der Verarbeitung mitberücksichtigt werden müssen.
Ein Teil der Strahlung wird direkt von der Atmosphäre zurück reflektiert ohne die Oberfläche zu erreichen somit tragen sie nur zum Strahlungshaushalt bei aber nicht zum Informationsgewinn über das Beobachtungsziel. Die überbleibenden Photonen beleuchten die Oberfläche abhängig von ihrem gestreuten Pfad diffus und werden auf ihrem Weg Richtung Weltraum bzw Sensor erneut gestreut, reflektiert und erneut gestreut (Trappingeffekt). Kurz es verlangt nach einer genauen Bestimmung der absorbierenden Gase der Atmosphäre sowie eine genaue Behandlung der Streuprozesse in Kombination beider Prozesse.

Absorptions- und Streuungseffekte

Die absorbierenden Gase Sauerstoff (O_2), Kohlendioxid (CO_2), Methan (CH_4) und Distickstoffmonoxid (N_2O) werden als Konstant in der Atmosphäre angenommen. Wasser (H_2O) und Ozon (O_3) werden als zeit- und orts-

abhängig betrachtet. Gase Absorbieren Strahlung indem sie ihre Rotations, Vibrations- sowie Elektronischen Zustände verändern. Veränderungen der Rotation werden im Mikrowellen oder fernen Infrarot sichtbar und sind typisch für schwache Frequenzen. Veränderungen in der Vibration sind im Nahen Infrarotbereich angesiedelt. Elektronische Veränderungen können im sichtbaren und ultravioletten Bändern sichtbar gemacht werden. Die Absorptionskoeffizienten variieren sehr stark mit der unterschiedlichen Wellenlänge und stellen ein sehr komplexes Konstrukt dar. H_2O beeinflusst hauptsächlich Wellenlängen die größer als $0.7\mu m$sind. O_3 hat seine größte Absorptionsfähigkeit zwischen $0.55 - 0.65\mu m$ und limitiert die Erdbeobachtung auf Wellenlängen größer $0.35\mu m$. CO_2 beeinflusst Wellenlängen größer $1\mu m$ jedoch nicht so stark wie H_2O und wirkt störend auf den Wasserdampf. O_2 stärkster Einfluss ist um ca $0.7\mu m$, CH_4 zeigt besonders starken Einfluss bei 2.3 bzw bei 3.35, N_2O hat ebenfalls in zwei Bereichen einen starken Einfluss und zwar bei $2.9\mu m$ und $3.9\mu m$.

Bei der Annahme das die Oberfläche einheitliche lambertsche Reflexionseigenschaften aufweist und die Atmospäre horizontal einheitlich geschichtet ist wird die Reflexion als

$$\rho^* = \frac{piL}{\mu_s E_s} \tag{2.11}$$

L ... gemessene Strahlung (2.12)

E_s ... solare Flux am Atmosphären-beginn (2.13)

(2.14)

Berücksichtigt man atmopshärischen Einfluss, Absorbtionseffekte von H_2O, O_2, CO_2 und O_3, Streuung an Molekülen und Aerosolen und der Einfluss der Oberfläche, schreibt man nun
(Vermote et al., 2006)

$$\rho'(\Theta_s, \Theta_v, \Phi_v) = t_g(\Theta_s, \Theta_v) \left\{ \rho_a(\Theta_s, \Theta_v, \Phi_v) + \frac{T(\Theta_s)}{1 - \langle \rho(M) \rangle S} \left[\rho_c(M) e^{-\tau/\mu_v} + \langle \rho(M) \rangle t_d(\Theta_v) \right] \right\} \tag{2.15}$$

Auf eine genaue Diskusion wird Um eine erfolgreiche Kalibrierung mittels der 6S Methode durchführen zu können benötigt man Infromationen über

- geometrische Zustände der Strahlungsquelle und Sensor
- atmosphärische Modellierung der Gaskomponenten
- das Aerosolmodell
- spektralen Zustände
- die Bodenbeschaffenheit (Typ und Variation)

Für jeden Schritt in der Berechnung werden entweder standartisierte Zustände angenohmen oder selbsdefinierte fliessen ein. Die Satellitenposition wird generell als grob angenommen.

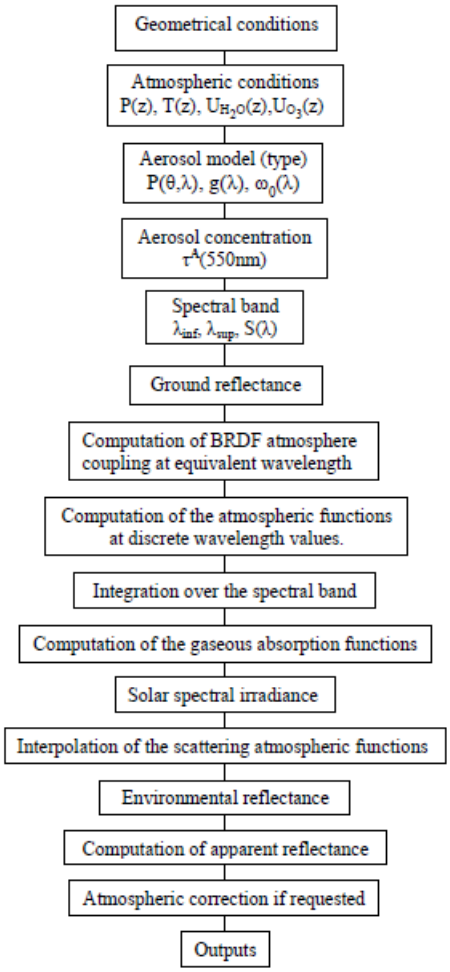


Abbildung 2.13: *Workflow der 6S Radiative Transformation Codes (Vermote et al., 2006)*

2.2.3.2 Bidirektionale Reflektionsverteilunsgfunktion

Die Bidirektionale Reflektionsverteilungsfunktionen (BRDF) beschreiben die Reflektionseigenschaften von Materialien und Oberflächen und Berücksichtigt den Einstrahlwinkel des Emitters sowie den Blickwinkel des aufnehmenden Sensors. Verschieden Materialien reflektieren bei gleicher Beleuchtung unterschiedlich. Manche Oberflächen zerstreuen das einfallende Licht difus während andere wiederum die Strahlung als Spiegel reflektieren. Generell ge-

ben sie an wie viel Licht von einer Oberfläche reflektiert wird abhängig von der pyhsikalischen Beschaffenheit (Wellenlänge) des ausgesendeten Lichtes sowie der Oberflächenbeschaffenheit und Zusammensetzung der reflektierenden Materie.

Die BRDF ist eine Funktion in vier Variablen

$$BRDF = f(\Theta_{in}, \Phi_{in}, \Theta_{ref}, \Phi_{ref}) = f(\mathbf{L}, \mathbf{V}) \tag{2.16}$$

wobei Θ_{in}, Φ_{in}, Θ_{ref}, und Φ_{ref} die Azimuth- und Deklinationswinkel der Einfalls- und Reflexionswinkel bezüglich der Strahlunsquelle sowie des Sensors sind. $\boldsymbol{L}$ bezeichnet dabei die Richtung der Lichtquelle und $\boldsymbol{V}$ die Richtung des Senors auf die Oberfläche. Ohne jetzt weitere Einflussparameter zu nennen oder in die Tiefe zu gehen siehe [N. Gebhardt] beschreibt einen BRDF für eine speziel definierte Wellenlänge das Verhältnis zwischen der differentiellen Leuchtdichte $RadiancedL_{ref}$ in Beobachtungsrichtung und der differentiellen Bestrahlungsstärke $IrradiancedE_{in}$ die aus der Beleuchtungsrichtung auf die beschienene Oberfläche wirkt, beschreibt.

$$BRDF(\Theta_{in}, \Phi_{in}, \Theta_{ref}, \Phi_{ref}) = \frac{dL_{ref}(\Theta_{ref}, \Phi_{ref}}{dE_{in}(\Theta_{in}, \Phi_{in})} \tag{2.17}$$

Allgemein ist die BRDF eine Funktion die nur in drei Variablen abhängig ist $f(\Theta_{in}, \Theta_{ref}, \Phi_{in} - \Phi_{ref})$. Als weiterführende Literatur wird Nikolaus Gebhardt und Shree Nayar empfohlen.
Die Oberflächenalbedo variiert sehr stark abhängig von sesonalen oder geographischen Parametern. Regenfall kann zum Beispiel die Oberflächenalbedo einer Baumkrone um bis zu 50% reduzieren (Román et al., 2009). Zusätzlich dazu kommen noch Faktoren wie Schattenwurf durch Baumkronen oder spiegelnde Reflexionen abhängig vom Einfallwinkel des Sonnenlichtes oder atmosphärische Veränderungen und Schwankungen (Román et al., 2009).

2.2.3.3 MODIS (Collection V5) BRDF/albedo product

Der Algorithmuis beruht auf multitemporalen, wolkenfreien, atmosphärisch korregierten Oberflächenreflexionen der Terra und Aqua Satelliten um die

Anisotropie der Oberflächenreflexion über eine 16 Tage lange Periode zu modellieren. Verwendet wird dabei ein kernelbasiertes lineare Modell der BRDF auch bekannt als Ross-Lick/Li-Sparse-Reciprocal kernelartiges BRDF-Modell. Dieses Modell beruht auf den gewichteten Summen eines isotropischen Parameters sowie zwei Funktionen (oder Kernel) abhängig von Blickrichtung und Illumination. Θ steht für den solaren Zenithwinkel, ϑ Winkel unter dem der Pixel betrachtet wird, Φ ist der relative sonnengerichtet Azimuth in Blickrichtung des Senors und Λ ist das solarspektrale gewichtete Zentrum für ein gegebenes MODIS Band

$f_{iso}(\Lambda)$ ist die isotropische Streuungskomponente und gleich der bidirektionalen Reflexion bei einem Betrachtungswinkel von $\vartheta = 0$ und dem solaren Zenithwinkel $\Theta = 0$. $f_{geo}(\Lambda)$ ist der Koeffizient für des Li-Sparse-Reziproken geometrischen Streungskerne K_{geo} welcher sich aus der Oberflächenstreuung und der geometrischen Schattenwurf Theorie herleitet. Der Parameter $f_{vol}(\Lambda)$ ist der Koeffizient des Ross-Thick Volumens-Streuungskernel K_{vol}, welcher sich aus radiativen Transfermodellen. Die best gefitteten Ross-Thick/Li-Sparse-Reziproken (RTLSR) Modellparmater werden an den ersten sieben MODIS Spektralbändern angebracht. Zusammengesetzt sieht das Modell wie folgt aus

$$R(\Theta, \vartheta, \Phi, \Lambda) = f_{iso}(\Lambda) + f_{vol}(\Lambda)K_{vol}(\Theta, \vartheta, \Phi) + f_{geo}(\Lambda)K_{geo}(\Theta, \vartheta, \Phi). \tag{2.18}$$

Anhand von Integration über alle Blickwinkel ergibt sich ein Modell für einen direkte hemisphärische Reflexion (DHR) oder Black-Sky-Albedo (BSA). Die Integration über alle Illuminationswinkel führt zur Bihemisphärischen Reflexion (BHR) unter isotropischer Illumination oder einer White-Sky-Albedo (WSA).

$$BSA(\Theta_s) = \sum_N f_k h_k(\Theta_s) \tag{2.19}$$

$$WSA = \sum_k f_k H_k \tag{2.20}$$

$h_k(\Theta)$ stellt das Integral des BRDF Kernels k über einen gegebenen Beobachtungszenith und (...weiterschreiben / vergleich der Intergrationsparameter mit den Allgemeinen BRDF Parametern)

2.2.4 Relative Kalibrierung

2.2.4.1 Lineare Regression

Tokola et al. (1999) gehen von zwei Grundlegenden Strategien aus, die bei der relativen Datenkalibrierung angewandt werden können. Manche Methoden basieren auf der Verteilung der Bildinformation während andere auf paarweise Pixelbeziehungen abziehlen. Alle Regressionsmodelle wurden anhand von robusten Methoden berechnet, welche iterativ die Gewichte für die Regression neu berechnen. Um Band-zu-Band kalibrieren zu können wird folgendes Modell verwendet:

$$\hat{y_i} = \beta_0 + \beta_1 x_i \tag{2.21}$$

y_i ist hierbei ein Pixel eines Bandes aus einer nachfolgenden Epoche und x_i bezieht sich auf einen Pixel eines Bandes in einer früheren Epoche. Vermote und Saleous (2006) führen einen Kreuzkalibrierung zwischen AVHRR und MODIS über einem radiometrischen stabilem Wüstengebiet im Niger anhand einer lineraren Translation durch.

2.2.4.2 PIF's

In dieser Diplomarbeit werden als Ausgangsdaten der radiometrischen Kalibrierungsmethode mittels LEDAPS absolut kalibrierte Landsatdaten verwendet. Die Cross-calibration zweier Sensoren über einem radiometrisch stabilen Gebiet wird in der Literatur häufig angeführt. Bei diesen Pseudo-Invariant-Calibration Sites handelt es sich wiederholt um die selben Gebiete. Diese Sites wurden eigentlich dafür ausgesucht um die Langzeitstabilität eines Sensors zu überprüfen. Um die DN der Landsatdaten

2.3 Bestehende Software

2.3.1 LEDAPS - Landsat Ecosystem Disturbance Adaptive Processing System

Das Landsat Ecosystem Disturbance Adapticve Processing System (LEDAPS) wurde ursprünglich im Jahre 2006 von der National Aeronautics and Space Administration - Goddard Space Flight Center und der Universität von Maryland entwickelt um Top-Of-Atmosphere (TOA) Reflexionsprodukte aus Daten der Landsat Thematic Mapper (Landsat5) und dem Enhanced Thematic Mapper Plus Level1 (Landsat7) Sensoren zu generieren. Der in dieser Diplomarbeit verwendete Algorithmus wurde vom USGS für den

Landsat Surface Climate Data Record angepasst. LEDAPS setzt sich aus sechs Modulen zusammen die drei Schlüsseloperationen beinhalten.

1. Konvertierung von Digital Numbers (DN) zu TOA Reflexionen
2. Wolkenpixeldetektion anhand der TOA
3. Transformation der TOA zu Oberflächenreflexion mittels zusätzlichen Daten

Die atmosphärische Korrektur wird anhand eines 6S-Korrekturmodells gerechnet welche Druck, Wasserdampf, Ozon sowie geometrischer Höheninformation.

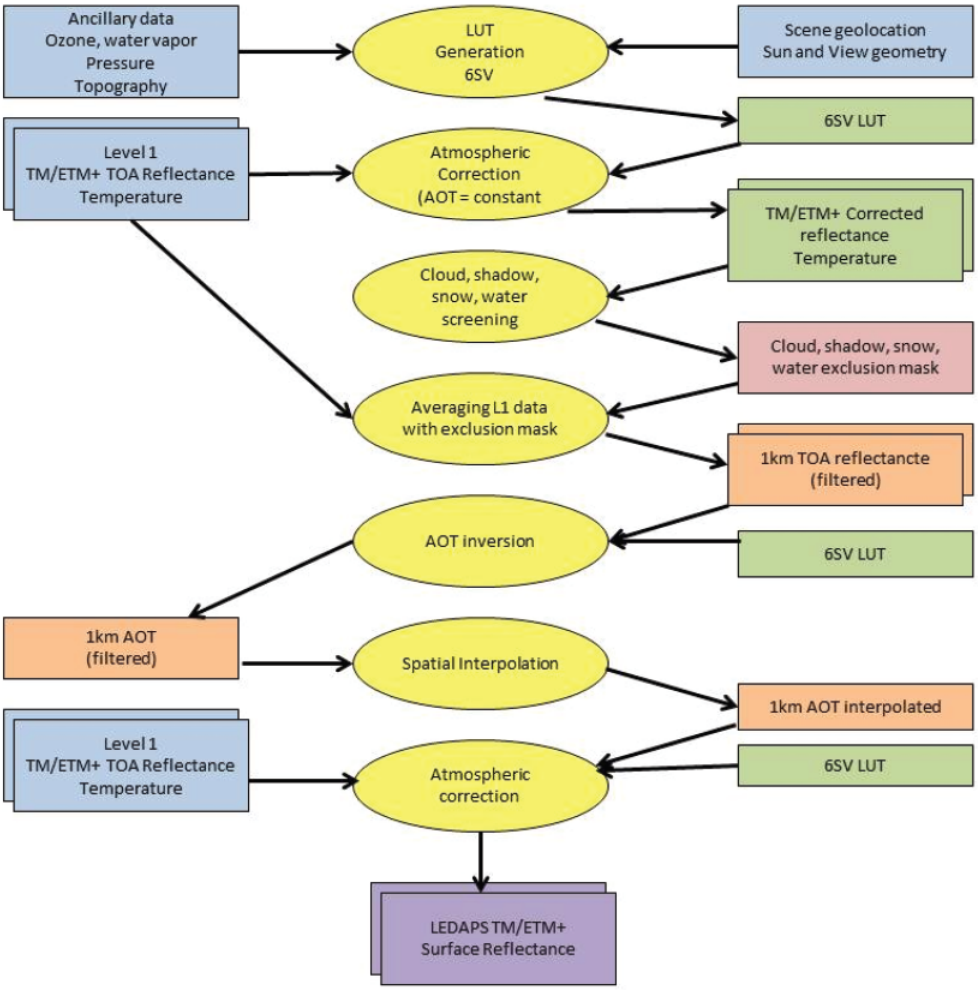


Abbildung 2.14: *Workflow der atmosphärischen Korrektur, (U.S.G.S., 2013)*

Für diese Diplomarbeit von besonderer Bedeutung ist die Qualitätsinformation die im gesamten Vorgang erstellt wird und weiterführend als Wolkenmaske verwendet wird. Das Modul 5 umfasst sämtliche Bearbeitungsschritte die zur Wolkendetektion verwendet werden. Hierfür werden die Bänder 1,3,4, und 6 sowie Zusatzinformation wie Lufttemperatur, Solarzenith, Solarazimuth etc zur Bestimmung verwendet. Sämtliche akquirierte Daten der Systeme Landsat5 TM und Landsat7 ETM+ werden in einem Vorverarbeitungsschritt diesem Algorithmus unterzogen.

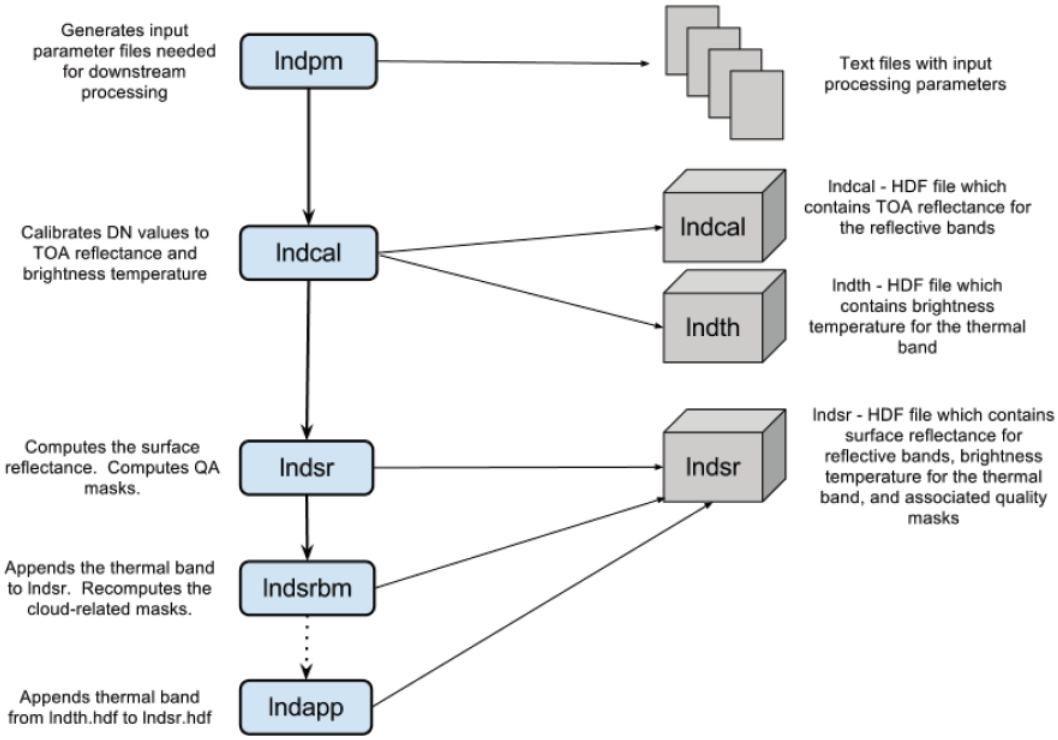


Abbildung 2.15: *Workflow des LEDAPS-Algorithmus, (U.S.G.S., 2013)*

Als Endergebnis liegen Landsat5 TM und Landsat7 ETM+ Daten als Oberflächenreflexion im hdf-Format vor.

2.3.2 TIMESAT

TIMESAT wurde primär zur Prozessierung von Vegetationsindexzeitreihen für die Ableitung von saisonalen Parametern wie Anfang, Ende, Länge etc der Vegetationsperiode entwickelt. Es erlaubt die Filterung von Satellitenbildzeitreihen sowie berücksichtigt es Zusatzinformation wie Qualitätsinformationen (z.B. Modis Qualitätsprodukt) für eine mögliche Gewichtung. Die verwendeten Algorithmen basierend auf der Methode der kleinsten Quadrate sind ein Savitzky Golay Filtern sowie zwei Methoden bei denen die Daten anhand von nonlinearer Funktionen unterschiedlicher Komplexität gefittet werden. TIMESAT arbeitet iterativ und mit einer dynamischen Gewichtung. Nach einer ersten Iteration und Schätzung der Parameter werden die Rohdaten-

werte unterhalb der gefitteten Kurve mit einem neuen geringeren Gewicht behaftet und das Modell wird neu berechent. Dadurch resultiert eine an den oberen Verlauf der Daten adaptiertes Modell.TIMESATs größter Nachteil ist die Prozessierungsgeschwindigkeit. In der Literatur wird TIMESAT meist nur für kurze Perioden oder einem beschränkten Gebiet eingesetzt siehe Jönsson und Eklundh (2004) sowie Tan et al. (2011). Bei der Prozessierung einer Zeitreihe die Daten von mehr als einem Jahrzehnt umfasst steigt die Rechenzeit und das Programm wird nicht mehr brauchbar.

Kapitel 3

Datengrundlagen

In diesem Kapitel werden die verwendeten Satellitendaten besprochen. Dabei handelt es sich um multispektrale Satellitendaten unterschiedlicher Auflösung und Datengehaltes sowie der Qualitätsinformation die bei der absoluten Kalibrierung der Landsatdaten mittels LEDAPS generiert wurde als fertiges Produkt für MODIS bereitgestellt wird.

3.1 Landsat - Allgemeine Informationen zum Sensor und Trägersystem

Landsat ist die weltweit längste zivile Erdbeobachtungsmission mittels Fernerkundungssensoren mittlerer Auflösung. Seit 1972 sind bis jetzt 8 Satelliten in Orbit gebracht worden wobei Landsat 6 beim Start verlorenging. Im näheren wird nur auf jene Sensoren eingegangen deren Daten in der Diplomarbeit verwendet wurden. Dies umfasst die Satelliten Landsat5, Landsat7 und Landsat8.

Landsat5 und Landsat4 (der Vollständigkeit halber erwähnt) wurden mit den verbesserten *Thematic Mapper* ausgestattet der im sichtbaren Bereich und nahen Infrarotbereich sowie im thermalen und panchromatischen Bereich Aufnahmen tätigt. Für das sichtbare und naheinfrarote Spektrum beträgt die Auflösung 30m, für das thermale Band 120m und im panchromatischen Kanal 15m.

Landsat7 führt den multispektralen *Enhanced Thematic Mapper Plus* (ETM+) mit sich, welcher im sichtbaren Bereich und nahen Infrarotbereich sowie im thermalen und panchromatischen Bereich Aufnahmen tätigt. Für das sichtbare und naheinfrarote Spektrum beträgt die Auflösung 30m, für das thermale Band 60m und im panchromatischen Kanal 15m. Der Satellit

führt drei on-board Kalibriereinrichtungen mit sich einen *Full Apertrure Solar Calibrator(FASC)*, einen *Partial Aperture Solar Calibrator (PASC)* und einen *Internal Calibrator (IC)*

Landsat8 wurde mit dem multispektralen Sensor *Operational Land Imager* (OLI) und dem *Thermal Infrared Sensor* (TIRS) ausgestattet. OLI liefert Aufnahmen in 8 spektralen Bändern in einer Auflösung von 30 m und einem panchromatischen Kanal in einer Auflösung von 15m. TIRS nimmt in zwei mittleren infraroten Bereichen in einer Auflösung von 100m auf. Da die TIRS Daten allerdings mit den OLI-Daten mitgeliefert werden, werden sie auf 30m neu aufgelöst.

Aktuell liefern Landsat7 und Landsat8 alle 16 Tage Aufnahmen des selben Erdoberflächenausschnittes. Die Orbits sind polare, sonnen-synchrone kreisförmige Bahnen in 705 km über Grund und ein Satellit umkreist die Erde in 99 Minuten. Die Bahnen der beiden Satelliten sind so synchronisiert das jeden achten Tag eine Aufnahmen des selben Beobachtungspunktes zur selben Uhrzeit vorliegt. Der beobachtete Groundtrack umfasst dabei einen 185 km breiten Streifen. Landsat5 hält bis jetzt den Rekord für den am längsten eingesetzten Erdbeobachtungssatelliten. Nach knapp 29 Jahren wurde seine Aktivität am 5. Juni 2013 eingestellt. Landsat7 weist seit dem 31 Mai 2003 Artefakte in seinen Satellitenbilddaten auf. Verursacht werden sie durch einen Defekt des *Scan Line Correctors* (SLC), der zur richtigen Abtastung des Beobachtungsgebietes bei Rotationsscannern eingesetzt wird. Seit diesem Ausfall finden sich zick-zack-artige Datenlücken in den Aufnahmen, die von einem zentralen nicht betroffenem Streifen horizontal nach außen laufen und von innen nach außen sich verbreitern.

3.2 Landsat

Die Daten des Landsatsystems wurden alle über die von der NASA und U.S.G.S. zur Verfügung gestellten Downloadsites *Earth Explorer* sowie *GloVis* akquiriert. Eine Landsatszene definiert ihre Position über Path- und Row- Angaben welche für das ausgewählte Gebiet der Diplomarbeit im Schwarzwald liegen Pathindizes von 195 bis 196 sowie Rowindizes von 25 und 26 umfasst. Der maximale Bewölkungsgrad wurde mit 40% gewählt. Sämtliche Landsat5 und Landsat 7 Satellitendaten wurden entweder direkt mit der *Bulk Download Application* (BDA) der NASA downgeloadet oder über deren Bestellservice geordert und sobald fertig prozessiert ebenfalls mittels der BDA downgeloadet. Die Daten liegen als GeoTIFF für jedes einzelne Band pro Epoche auf. Sämtliche Landsatdaten wurden im Anschluss

mittels LEDAPS absolut kalibriert. Die Kalibrierung liefert nicht nur die Landsatdaten in Oberflächenreflexion sondern vor allem die notwendige Wolkenmaske für jede zu kalibrierende LandsatSzene. Da LEDAPS seinerseits alle seine Ergebnisse als hdf4 verspeichert müssen diese ebenfalls wieder in das GeoTIFF-Format übergeführt werden.

3.3 MODIS - Allgemeine Informationen zum Sensor und Trägersystem

MODIS (Moderate Resolution Imaging Spectroradiometer) nennt sich ein optischer Sensor, welcher sich in einem Low Earth Orbit in 705 km Höhe, mit einer Blickwinkel von 2330 km auf den beiden Satelliten Terra (früher EOS AM-1) und Aqua (früher EOS PM-1) um die Erde befindet. Die Mission wurde am 18. Dezember 1999 mit dem Launch des Terra (EOS AM-1) Spacevehicles gestartet. Am 4. Mai 2002 wurde der Satellite Aqua (EOS PM-1) mit dem zweiten MODIS in seine Umlaufbahn geschossen. Die Lebenszeit von Terra und Aqua war mit jeweils 6 Jahren anberaumt und erfreut sich nun über ein mehr als 15 jähriges Bestehen. Die Orbits der Satelliten sind so synchronisiert, dass Terra den Äquatior am Vormittag von Nord nach Süd passiert und Aqua den Äquator nachmittags von Süd nach Nord. Die räumliche Auflösung eines einzenlnen Pixels reicht von 250 und 500 Metern im Nadir bis zu 1 km als Whisk-Broom-Scanner. Die Bänder 1-2 werden in 250m, die Bänder 3-7 in 500m und die Bänder 8-37 werden in 1000m Auflösung aufgenommen. Beide Satelliten vermögen in einer ein bis zwei Tage Periode die gesamte Erdoberfläche in 36 spektralen Bändern in einem Umfang von 0.4μ m bis 14.4μ m aufzunehmen. Die Aufnahmen finden dabei jeweils unter einem anderen Einstrahlwinkel, bidirektional, der Sonne statt. Nach der Anwendung von atmosphärischen Korrekturen und der Überführung der Strahlungswerten in Reflexionswerten der Erdoberfläche gibt das System die anisotropischen Reflexionseigenschaften mit dem Wandel der Landbedeckungstypen, Vegetation sowie Bodenkomponenten in jedem einzelnen Pixel wieder. Anhand von State-of-the-Art On-board-Kalibrierungseinheiten wird eine Genauigkeit von unter 2% angegeben (Vermote & Saleous, 2006). MODIS Terra wird generell als einer der am besten kalibierten Sensoren im Bereich der „reflektierenden“ Wellenlängen mit einer Unsicherheit von 2% (Helder et al., 2013).

BANDNAME	MODIS	nm	Landsat 7	nm	LANDSAT 5	nm	LANDSAT 8	nm
RED	Band 1	620-670	Band 3	630-690	Band 4	630-690	Band 5	630-680
NIR	Band 2	841-876	Band 4	750-900	Band 4	760-900	Band 5	845-885
BLUE	Band 3	459-479	Band 1	450-515	Band 1	450-520	Band 2	450-515
GREEN	Band 4	545-565	Band 2	525-606	Band 2	520-600	Band 3	525-600
MIR	Band 5	1230-1250	Band 6	1040-1250	Band 6	1040-1250	Band 9	1360-1390
MIR	Band 6	1628-1652	Band 5	1550 - 1750	Band 5	1550-1750	Band 6	1560-1660
MIR	Band 7	2105-2155	Band 7	2090-2350	Band 7	2080-2350	Band 7	2110-2300

Tabelle 3.1: Vergleich der aufzunehmenden spekrtalen Wellenlängen Bandweise MODIS zu Landsat Satelliten

3.3.1 MODIS - Compositemethoden

Der Grundgedanke des MODIS Compositionalgorithmus ist aus einem zeitlich vordefiniertem Pool an Epochen mittels einer reflexionsbasierten BRDF (Bi-directional Reflectance Distribution Function) mit einem eingeschränktem MVC (Maximum Value Composite) als Rückversicherung.

3.3.1.1 Maximum Value Composite

Das Maximum Value Composite (MVC) Verfahren zieht aus einem zeitlich vordefiniertem Pool für den NDVI den maximalen Wert jedes Pixels und trägt ihn in die abschliessende Epoche ein. Diese Vorgehensweise ist so geschaffen um störende atmosphärische Effekte zu minimieren , Wolken inkludiert. Der Kompositionsvorgang inkludiert in der Regel ein Wolkenscreening sowie einen Qualitätscheck der Daten. Die MVC funktioniert eher über Oberflächen mit Lambert'schen Eigenschaften, bei sich ändernden atmosphärischen Eigenschaften und anisotropischem Oberflächenverhalten wird die Methode jedoch ungenau (Van Leeuwen et al., 1999). Nach atmosphärischer Korrektur nimmt die Ungenauigkeit der MVC noch zu da die Anisotropie der Oberflächen ebenfalls zunimmt. Generell arbeitet die MVC am besten bei atmosphärisch unkorregierten Daten und ist ungeeignet für die atmosphärisch korregierten Oberflächenrefelxions Daten des MODIS-Sensors. Der NDVI tendiert zu einer Zunahme nachdem er aus atmosphärisch korregierten Daten berechnet wurde, jedoch bedeutet der höchste NDVI für ein Pixel noch nicht, dass es auch um den besten atmosphärisch korregierten Pixel handelt. Nicht entfernte Wolken und sowie unterschiedliche Sonnen- und Beobachtungswinkel verändern die Oberflächenrefelxion und somit den ausgewählten maximalen Wert. Über das Jahr gesehen wäre somit der Pixel nicht konsistent (Van Leeuwen et al.,

1999). Generell überschätzt das MVC-Verfahren die Rasterwerte und führt in weiterer Folge auch zu einer Überschätzung der abgeleiteten Parameters (Van Leeuwen et al., 1999). Wird der NDVI nun aus atmosphörisch korregierten Daten berechnet, so sind vor allem Pixel im Off-Nadir Bereich mehr fehlerbehaftet, da hier die Korrektur nicht so gut funktioniert. Einhergehend mit der immer weiter voranschreitenden Verbesserung und Entwicklung der atmosphärischen Korrekturalgorithmen wird bidirektionale Reflexion an Bedeutung gewinnen, da hier die unterschiedliche Struktur der Oberflächenbedeckung mit berücksichtigt werden kann.

3.3.2 Datenakquisition - v5

Die rohen MODIS-Zeitreihe liegt als verrauschete Zeitreihe von 2000-2012 im hdf-4 Format vor und wurden mittels der NASA-eigenen Software „MRT-TOOL“ in das GeoTIFF-Format entpackt und in das Sinusodial Reference System transformiert. Die Zeitreihe an sich selbst, setzt sich aus 16-Tägigen Kompositionen der besten spektralen Einzelaufnahme eines Pixels zusammen. Abhängig von der Auflösung des verwendeten Produktes zum Beispiel im 250 Meter aufgelöstem Produkt kann auch zwischen den Aufnahmen des Terra Satelliten mit dem Postfix "MODünd dem Aqua Satelliten mit dem Postfix "MYDünterschieden werden, welches zusätzlich in der Programmierung bedacht werden muss. Aufgrund der unterschiedlichen Launchzeitpunkte der Satelliten wurde die Zeitreihe zwischen 2000 und der ersten Aqua-Aufnahme künstlich verdichtet, indem die Terra-Aufnahmen einfach verdoppelt wurden und einen passenden Zeitstempel erhalten haben. Die komplettierte Zeitreihe an sich selbst weist alle 8 Tage eine Epoche eines MODIS-Sensors (Terra und Aqua-Epochen immer abwechselnd) auf.Für die Diplomarbeit selbst beschränkt sich der Author auf das „500m“ aufgelöste Produkt MCD43A4 welches alle 8 Tage Daten des Terra- oder des Aqua-Satelliten inklusive die passende Qualitätsinformation zur Verfügung stellt. Trotz des einwandfreien Rufes einer perfekten radiometrischen Korrektur der MODIS-Daten wurden Störungen in der visuellen Kontrolle ausfindig gemacht und die Zeitreihe anhand eines Glättungsalgorithmus nach Savitzky-Golay verbessert. Somit liegt eine europaweite wolkenfreie MODIS-Zeitreihe in 500 Meter Pixelauflösung als Basis für die relative Kalibrierung der Landsatdaten bereit.

3.3.3 Datenakquisition - MODIS Zeitreihe V6

3.3.3.1 MODIS Data General Describtion

MCD steht für eine Kombination aus TERRA und AQUA Daten, welche für die Herstellung dieses Produktes herangezogen wurden, um die größt mögliche Güte der Qualitätsinformation zu gewährleisten. Der herangezogene Zeitraum beträgt 16 Tage und das Datum des Files repräsentiert dabei das Zentrom des Moving-16-tages-Windows [1]. Die täglichen Produkte werden hinsichtlich ihrer Qualität, Beobachtungsabdeckung und zeitlichen Distanz zum interessierenden Zeitpunkt gewichtet [4]. MCD43 Produkte verwenden L2G-lite Daten als Input [3]. Wenn zuwenige Beobachtungen vorliegen (aus den unterschiedlichen Orbits), dann wird mit Hilfe einer Datenbank, welche urtypische BRDF Parameter enthält eine "lower-magnitudeİnversion durchgeführt und angewandt[3]. Die rohen MODIS Datenpunkte mit der Kennung MCD43A4 und den epochenweisen zugehörigen Qualitätsinformation mit der Kennung MCD43A2 liegen als HDF4 auf einem Server des United States Geological Survey (USGS) auf und können dort über die Website [1] bezogen werden (eine Registrierung wird vorausgesetzt). Das HDF4 Format ist ein Containerformat das unterschiedlichste Datentypen kombiniert in einem File hierarchisch bzw multidimensional verspeichern kann. Vorteil ist vor allem bei diesem Format, dass man auch an bestehenden Dateien neue Daten anhängen kann.

3.3.3.2 MCD43A4 NBAR Data

MODIS MCD43A4 Version 6 ist ein Nadir BRDF (Bidirectional Reflectance Distribution Function) angepasstes Reflexionsprodukt (NBAR) aus ebenfalls 16 tägigen Auqa und Terra Daten. Die Daten werden für den Sonnenhöchststand der Tagesepoche berechnet [9]. Daraus resultiert ein stabiles und konsistentes NBAR Produkt. Die Daten werden mit einem überblicksartigen Qualitylayer für jedes Band in einem HDF Stack verspeichert. Es wird jedoch explizit darauf hingewiesen bei Berechnungen oder sonstiger Verwendung die Qualityinfo aus den MCD43A2 Produkten zu verwenden, da diese eine höhere Genauigkeit aufweisen. Die berechneten Reflexionswerte werden für jede Band als Rasterdaten in 16bit verspeichert. Fill value oder NoDate value ist 32767 [←8].

[1] https://e4ftl01.cr.usgs.gov/MOTA/

3.3.3.3 MCD43A2 Quality Product

Die Beobachtungen sind auf den neunten Tag der 116 Tagesperiode gewichtet [3]. Dies führt auch zu einer besseren Qualität in höheren Breiten. Im Vergleich hierzu, Version 5 verwendet ein Fenster von nur vier Beobachtungen pro Tag [3]. Die Qualitätsinformation für die Bänder 1 - 7 befinden sich im HDF-Stack des Qualitätsproduktes in den Layern 11-17 und weisen die Qualität nach folgendem Schlüssel aus [7]

- 0 = best qualiy, full inversion (WoDs, RMSE majority good)
- 1 = good quality, full inversion (also including the cases that no clear sky observations over the day of interest or the Solar Zenith Angle is to large even WoDs, RMSE majority good)
- 2 = Magnitude inversion (numobs >=7)
- 3 = Magnitude inversion (2>= numobs <7)
- 4 = Fill value

Der Fill value ist mit 255 dem NoData Value gleichzusetzen, da er so in den Qualitätsdaten vorkommt.

Layer-ID	Layername
0	MOD_Grid_BRDF:BRDF_Albedo_Band_Mandatory_Quality_Band1
1	MOD_Grid_BRDF:BRDF_Albedo_Band_Mandatory_Quality_Band2
2	MOD_Grid_BRDF:BRDF_Albedo_Band_Mandatory_Quality_Band3
3	MOD_Grid_BRDF:BRDF_Albedo_Band_Mandatory_Quality_Band4
4	MOD_Grid_BRDF:BRDF_Albedo_Band_Mandatory_Quality_Band5
5	MOD_Grid_BRDF:BRDF_Albedo_Band_Mandatory_Quality_Band6
6	MOD_Grid_BRDF:BRDF_Albedo_Band_Mandatory_Quality_Band7
7	MOD_Grid_BRDF:Nadir_Reflectance_Band1
8	MOD_Grid_BRDF:Nadir_Reflectance_Band2
9	MOD_Grid_BRDF:Nadir_Reflectance_Band3
10	MOD_Grid_BRDF:Nadir_Reflectance_Band4
11	MOD_Grid_BRDF:Nadir_Reflectance_Band5
12	MOD_Grid_BRDF:Nadir_Reflectance_Band6
13	MOD_Grid_BRDF:Nadir_Reflectance_Band7

Abbildung 3.1: *Layerhierarchie eines HDF4 Files*

In den Datenfiles sind auch Qualitätsinformationslayer enthalten, diese bieten jedoch nicht die Genauigkeit des Qualitätsproduktes MCD43A2.

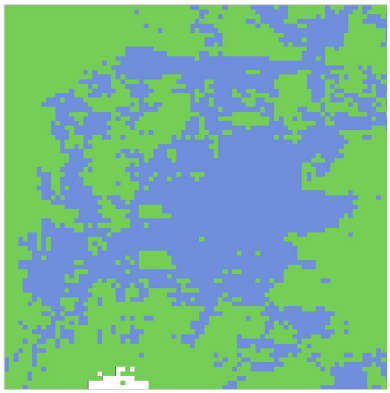


Abbildung 3.2: Qualitätsinformation aus dem Datenprodukt

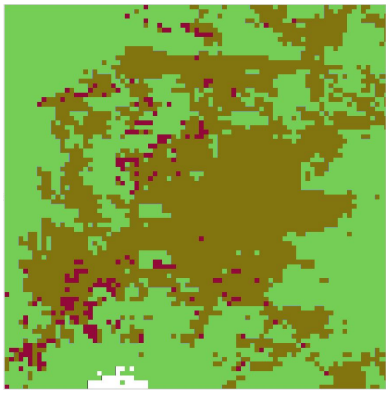


Abbildung 3.3: Qualitätsinformaion aus dem Qualitätsprodukt

Der Dateiname jeder Datenepoche oder der zugehörigen Qualitätsinformation beinhaltet

- Dateiname=MCD43A4.A2000057.h18v04.006.hdf
- Produkt = MCD43A4 (hier Datenprodukt)
- Day Of Year = A2000057
- Kachel = h18v04
- Version = 006
- Fileextension = hdf

Um ein Jahr zu rekonstruieren bzw zu filtern werden 46 Datenpunkte verwendet. Dies entspricht den Day of Year von 001 bis 361 in einem Intervall mit an jedem 9.ten Tag einen Datenpunkt. Da es sich für den in Betracht gezogenen Zeitraum 2000-2020 um 927 Datenpunkte pro Kachel handelt, wurde hier mit Python bzw den Bibliotheken *requets, bs4* ein Webscrabber-Skript geschrieben, welches alle Metadaten für die zu interessierenden Daten erstellt und aus der passenden Ordnerstruktur am USGS Server downloaded und in einer passenden Ordnerstruktur lokal verspeichert.

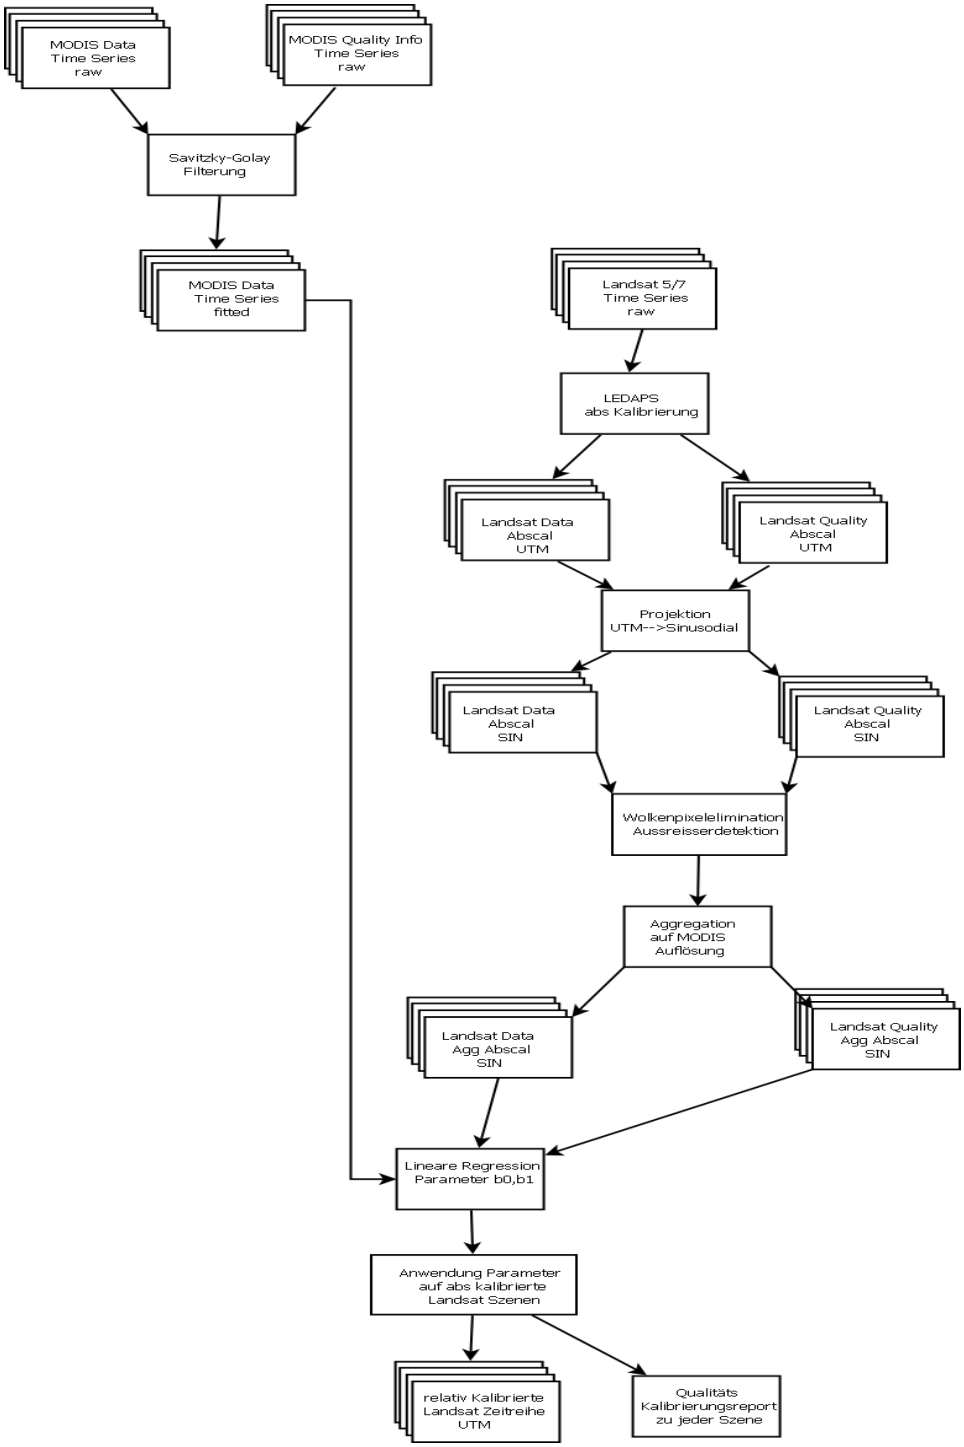


Abbildung 3.4: *Workflow der relativen Kalibrierung von Landsatdaten mittels gefilterter MODIS Zeitreihe*

3.4 Sentinel

Sentinel sind eine Reihe von Erdbeobachtungs- und Forschungssatelliten der ESA welche im Rahmen des Copernicus Forschungsprogramms gestartet und zum Einsatz kommen. Sie setzten sich aus 5 Satelliten zusammen die im optischen und Radarbereich eine dichte Bandbreite an Informationen über den Planeten sammeln. Sentinel 2 liefern Daten im optischen, nahen infraroten Bereich, hochauflösend von 10 mal 10 Meter, in einem Intervall von 5 Tagen. Dies gewährt Aussicht auf besonders dichte Zeitreihen die mit diesem System möglich sind. Sentinel 3 nimmt die Erdoberfläche mit einer höheren Auflösung auf , soll allerdings zumindest auf dem Level der MODIS Daten kalibriert sein. Die entwickelte Methodik zielt auch auf eine portable Herangehensweise ab, dass man die besser kalibrierten Sentinel 3 Daten zum Kalibrieren von Satellitendaten anderer Syteme verwendet.

3.5 Sinusodial Referenzsystem

Die Daten der verwendeten MODIS-Zeitreihe wurden mittels dem MODIS-Reprojection-Tool in eine Sinusoidale Projection gebracht. Die Sinusoidal-Projektion nist eine flächentreue, pseudo-zylindrische Projektion, welche die gesamte Erdoberfläche darstellen kann. Der Zentralmeridian und der Äquator werden winkel- und längentreu wiedergegeben während Meridiane als Sinuskurven und Breitenkreise als Geraden dargestellt werden. Als Basis dient eine Kugel mit einem gemittelten Erdradius von 6371007,181 m (MODIS Land, web-quelle nr 11). Je weiter man sich vom Abbildungsmeridian entfernt umso verzerrter wird die Darstellung. Die meisten MODIS Land Produkte sind als Kacheln indiziert und nutzen das Sinusodial-Grid-Tilling-System. Am Äquator weist eine Kachel eine Größe von 10 Grad mal 10 Grad auf. Das Kachelkoordinatensystem startet bei (0,0) - (horizontale nummer, verticale nummer) in der linken oberen Ecke beginnt und bei (35,17) in der rechten unteren Ecke endet. Das System zählt dabei von rechts nach links (horizontal) und von oben nach unten (vertikal)

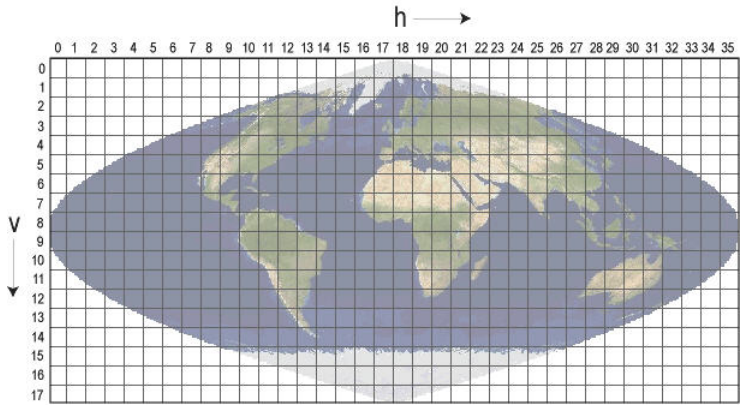


Abbildung 3.5: *MODIS Tilling System, (U.S.G.S., 2013)*

3.6 UTM-Referenzsystem

Sämtliche Daten der Landsatmissionen sind im *Universal Transverse Mercator*-Referenzsystem (UTM) projiziert. Es handelt sich hierbei um ein globales Koordinatensystem das die Erdoberfläche von 80 Grad Süd bis 84 Grad Nord streifenförmig in 6 Grad breite Zonen unterteilt. Als Basis dient das Bezugsellipsoid WGS84. UTM nutzt eine transversale Mercator-Projektion zum verebnen. Hierbei berührt der Projektionszylinder die Oberfläche nicht am Bezugsmeridian sondern schneidet sie. Dadurch ensteht ein Streifen

Kapitel 4

Methodik

4.1 mathematische Grundlagen

Das Hauptziel der Diplomarbeit besteht darin, aus einer dichten Zeitreihe von atmosphärisch gut korrigierten MODIS-Satellitenbilddaten anhand von statistischen Methoden und Werkzeugen Landsat TM und Landsat ETM+ Satellitenbilddaten in Oberflächenreflexion überzuführen und radiometrisch zu verbessern. In diesem nachfolgenden Kapitel wird auf die mathematischen und statistischen Grundlagen eingegangen die für das Verständnis von Nöten sind. Die verwendeten Informationen stammen zumeist aus *Regresison* (Härdle, 2007) sowie dem Vorlesungsskriptum aus *Parameterschätzung* von (Pail, 2010).

4.1.1 statistische Kennzahlen

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i \qquad \dots \; Mittelwert \tag{4.1}$$

$$\bar{\sigma^2} = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2 \qquad \dots \; Varianz \tag{4.2}$$

$$\sigma = \sqrt{\sigma^2} \qquad \dots \; Standardabweichung \tag{4.3}$$

4.1.2 Lineare Regression

4.1.2.1 OLS - das klassische lineare Modell

Generell gilt der Zusammenhand das y, die Variable die primär von Interesse ist, eine Funktion von $x_1, \dots, x_k$ ist. Allgemein wird der Zusammenhang

zwischen y und $x_1, \ldots, x_k$ als Funktion $f(x_1, \ldots, x_k)$ beschrieben. Da diese Beziehung nicht exakt gemessen werden kann wird diese Beziehung immer durch zufällige Störungen verzerrt.

$$y = f(x_1, \ldots, x_k) + \epsilon \tag{4.4}$$

Generelles Ziel ist die Schätzung der zugrundeliegenden unbekannten Funktion f. Über die unbekannte Funktion f und den Fehler ϵ werden folgende Annahmen getroffen:

1. Die systematische Komponente f ist eine Linearkombination der Kovariablen
   Anhand der Kovariablen wird die Funktion als Linearkomination modelliert.
   $$f(x_1, \ldots, x_k) = \beta_0, + \beta_1 x_1 + \cdots + \beta_k x_k \tag{4.5}$$

   Die Parameter $\beta_0, + \beta_1 x_1 + \cdots + \beta_k x_k$sind allesamt unbekannt und werden geschätzt, wobei β_0 als Konstante verwendet wird (Intercept). Zusammengefasst in Vektoren mit der Dimension $p = (k + 1), x = (1, x_1, \ldots, x_k)'$ und $\beta = (\beta_0, \ldots, \beta_k)$ ergibt sich die kompaktere Schreibweise
   $$f(x) = x'\beta \tag{4.6}$$

2. Additivität der Störgröße Die Additivität der Störgröße wird als weitere Grundanahme des linearen Modells angenommen

   $$f(x) = x'\beta + \epsilon \tag{4.7}$$

   Für die zu schätzenden unbekannten Parameter β zu den erhobenen Daten y_i sowie $x = (1, x_1, \ldots, x_k)', i = 1, \ldots, n$ existiert eine Beobachtungsgleichung für jede Beobachtung

   $$y_i = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k + \epsilon_i = x_i'\beta + \epsilon_i \tag{4.8}$$

   Anhand der Vektoren

   $$y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} \qquad \textit{sowie} \qquad \epsilon = \begin{pmatrix} \epsilon_1 \\ \vdots \\ \epsilon_n \end{pmatrix} \tag{4.9}$$

und der Designmatrix X

$$P_{ij} = \begin{pmatrix} 1 & x_{11} & \dots & x_{1k} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \dots & x_{nk} \end{pmatrix} = \begin{pmatrix} x'_1 \\ \vdots \\ x'_n \end{pmatrix} \tag{4.10}$$

kann eine bequeme Matrixschreibweise angeführt werden:

$$y = \tag{4.11}$$

4.1.3 Harmonische Schwingungen - Fourier Analyse

4.1.3.1 Harmonische Schwingungen , Diskrete Fourier Transformation und Analyse

Da sich die Natur recht gut mit periodischen Funktionen beschreiben lässt, wurden auch hier einige Methoden aus der Signalanalyse und Verarbeitung gewählt um die Daten einer Zeitreihe der vorhandenen MODIS Satellitendaten zu analysieren, rekonstruieren und zu verbessern. Die Zerlegung nach Frequenzen entspricht dem, was ein Prisma mit dem einfallenden Licht macht. Der Lichtstrahl - zum Beispiel ein Sonnenstrahl - ist meist eine Überlagerung von Beiträgen verschiedenster Frequenzen. Da die Lichtbrechung beim Prisma frequenzabhängig ist, wird der Strahl zerlegt, der Ausfallwinkel hängt von der Frequenz des entsprechenden Anteils ab. Diese Zerlegung ist nichts anderes als die Projektion auf die Basisvektoren des Vektorraums periodischer Funktionen in L^2. Die Methode heißt Fourierzerlegung oder **Fourieranalyse**, die Zusammensetzung der Funktion als Summe ihrer Komponenten ist die **Fouriersynthese** (Christian B. Lang, Norbert P. 2005).

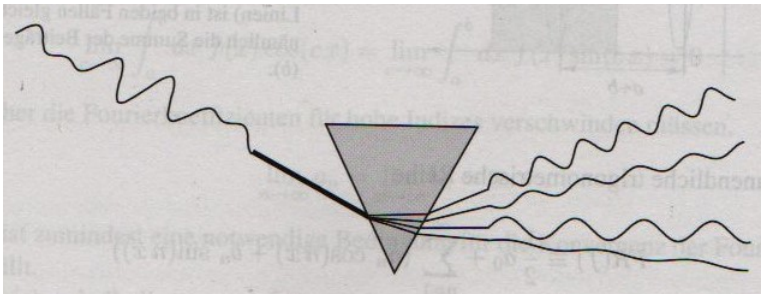


Abbildung 4.1: *Aufteilung eines Lichtstrahls in seine Frequenzbereiche (Christian B. Lang, S401)*

Die Daten der zu analysierenden Zeitreihe sind in der Regel keine reine sinusförmige Schwingung, besitzt jedoch ebenfalls eine Schwingungsdauer T und eine Kreisfrequenz $\omega_0 = 2\pi/T$. Diese zeitabhängige, periodische Funktion $y(t)$ lässt sich dann unter den bekannten Voraussetzungen in eine Fourier-Reihe vom Typ

$$\begin{aligned} y(t) &= \frac{a_0}{2} + \sum_{n=1}^{\infty}[a_n \cdot cos(n\omega_0 t) + b_n \cdot sin(n\omega_0 t)] = \\ &= \frac{a_0}{2} + a_1 \cdot cos(\omega_0 t) + a_2 \cdot cos(2\omega_0 t) + a_3 \cdot cos(3\omega_0 t) + \ldots \\ &\ldots + b_1 \cdot sin(\omega_0 t) + b_2 \cdot sin(2\omega_0 t) + b_3 \cdot sin(3\omega_0 t) + \ldots \end{aligned} \tag{4.12}$$

entwickeln. Diese Entwicklung in unendlich viele Sinus- und Kosinusfunktionen bedeutet aus physikalischer Sicht eine Zerlegung der Schwingung $y(t)$ in ihre harmonischen Bestandteile, auch Schwingungskomponenten genannt. Sie bestehen aus der Grundschwingung mit der Grundkreisfrequenz ω_0 und den harmonischen Oberschwingungen deren Kreisfrequenzen ganzzahlige Vielfache der Grundkreisfrequenzen sind: $2\omega_0, 3\omega_0, 4\omega_0 \ldots$. Bringt man umgekehrt Grundschwingungen und Oberschwingungen zur ungestörten Überlagerung, so erhaltet man als Resultierende genau die Schwingung $y = y(t)$ (Superpositionsprinzip der Physik [1]). Die Fourier-Koeffizienten $a_0, a_1, a_2, a_3, \ldots, b_1, b_2, b_3, \ldots$ bestimmen dabei die Amplituden der harmonischen Teilschwingung und somit letztendlich deren Anteile an der Gesamtschwingung (Lothar P., S182). Die als harmonische Analyse oder auch *Fourier-Analyse* bezeichnete Zerlegung einer nichtsinusförmigen Schwingung $y = y(t)$ in Grundschwingung und harmonische Oberschwingungen läuft somit auf die Bestimmung der Fourier-Koeffizienten in der Entwicklung nach der vorangegangenen Formel (4.12) hinaus.

$$y(t) = \frac{a_0}{2} + \sum_{n=1}^{\infty}[a_n \cdot cos(n\omega_0 t) + b_n \cdot sin(n\omega_0 t)] \tag{4.13}$$

Sie können mit Hilfe der folgenden Integralformeln berechnet werden (Lothar

[1] ungestörte Überlagerung (Interferenz) mehrerer Wellen des gleichen Typs. Hier können sich die Amplituden der (z.B. elektromagnetischen) Wellen beim Überlagern gegenseitig verstärken oder abschwächen

P., S183)

$$\omega_0 : \quad \text{Kreisfrequenz der Grundschwingung} \tag{4.14}$$

$$n\omega_0 : \quad \text{Kreisfrequenz harmonischer Oberschwingungen (n=1,2,3...)} \tag{4.15}$$

$$T = \frac{2\pi}{\omega_0} : \quad \text{Schwingungsdauer (Periode)} \tag{4.16}$$

$$a_0 = \quad \frac{2}{T} \cdot \int_T y(t)dt \tag{4.17}$$

$$a_1 = \quad \frac{2}{T} \cdot \int_T y(t) \cdot cos(n\omega_0 t)dt \ldots n = 1, 2, 3, ... \tag{4.18}$$

$$a_2 = \quad \frac{2}{T} \cdot \int_T y(t) \cdot sin(n\omega_0 t)dt \ldots n = 1, 2, 3, ... \tag{4.19}$$

Das Symbol T im Integral bedeutet, dass die Integration über ein beliebiges Periodenintervall von der Länge T zu erstrecken ist. Die Berechnung des Koeffizienten a_0 ist auch mit der Formel für $n = 0$ möglich, da $cos(0\omega_0 t) = cos0 = 1$ ist(Lothar P., 2013, S183).

Die Fourier-Analyse einer nicht-sinusförmigen Schwingung $y = y(t)$ lässt sich auch in komplexer Form vornehmen:

$$y(t) = \sum_{n=-\infty}^{\infty} c_n \cdot e^{jn\omega_0 t} \tag{4.20}$$

Die Berechnung der komplexen Fourierkoeffizienten c_n erfolgt mit der Integralformel

$$c_n = \frac{1}{T} \cdot \int_0^T y(t) \cdot e^{-jn\omega_0 t}dt \tag{4.21}$$

Wobei ω_0 und T wieder wie folgt sich zusammen setzen

$$\omega_0 \quad : \quad \text{Kreisfrequenz der Schwingung} \tag{4.22}$$

$$T \quad : \quad \text{Schwingungs- oder Periodendauer}(T = 2\pi/\omega_0) \tag{4.23}$$

Die Umrechnung zwischen den reellen und der komplexen Darstellung erfolgt über folgende Gleichungen:

$$c_0 = \frac{1}{2}a_0, \quad c_n = \tfrac{1}{2}(a_n - jb_n), \quad c_{-n} = c_n^* = \frac{1}{2}(a_n + jb_n) \tag{4.24}$$

Die Umrechnung komplexer zur reellen Form passiert wie folgt:

$$a_0 = 2c_0 \qquad a_n = c_n + c_{-n} = c_n + c_n^* \tag{4.25}$$

$$b_n = j(c_n - c_{-n}) = j(c_n - c_n^*) \tag{4.26}$$

4.1.3.2 Rekonstruktion mittels FFT

Die Fast Fourier Transformation (FFT) is eine wichtige und bekannte Methodik aus der Signalverarbeitung, welche ein Signal in ihre einzelnen Spektralkomponenten zerlegt und Aufschluss über deren Zusammensetzung gibt, Der Kern einer FFT ist eine Diskrete Fourier Transformation (DFT), jedoch ist der dahinterliegende Algorithmus optimiert, wovon auch der der Namen herrührt, sprich man verwendet die FFT um die Koeffizienten einer DFT zu ermitteln. Die FFT reduziert die Anzahl der Berechnungen für eine Anzahl **N** erheblichst

$$\begin{aligned} n &= 44000 \\ DFT &= O(N^2) = O(44000^2) = 1963000000 \\ FFT &= O(N \cdot log_2(N)) = O(4400 \cdot log_2(44000)) = 204311 \end{aligned} \tag{4.27}$$

Dies merkt man besonders wenn man große Mengen an Daten verarbeitet. Wie vorhin schon erwähnt ist die Fourier Transformation eine mathematische Operation, welche die Domäne der Zeit eines Signals in die Frequenzdomäne überführt, sprich in seine Frequenzanteile zerlegt und dadurch analysiert werden können. Bei der FFT wird ein zeitlich begrenztes Signal herangezogen und in seine Frequenzanteile zerlegt sowie deren Phasen und Amplituden bestimmt. In der Praxis wurde auf die bereits existierenden Routinen in **numpy 1.19.2** zurück gegriffen.

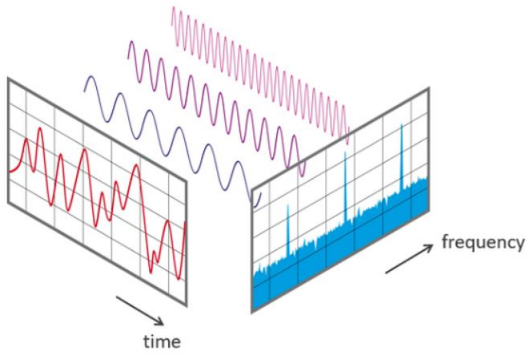


Abbildung 4.2: *Aufteilung eines Signals in Zeit- und Frequenzbereich*

$$\hat{x_k} = \sum_{i=1}^{n-1} x_i \qquad \dots \; FFT \tag{4.28}$$

Bei genauerer Betrachtung des MODIS Datenmaterials stellt man fest, dass der Idealzustand bzw die optimalen Vorraussetzungen bei der Berechnung der Reflexionswerte eher selten vorhanden sind. Dies äussert sich als schlechtere Pixelqualitätsinformation oder gar ein nichtvorhandener Wert der durch einen Füllwert repräsentiert wird. Die FFT ist jedoch ein sehr robuster Algorithmus der auch sehr gut bei verrauschten Signalen die wichtigsten Frequenzen heraus filtert. Voraussetzung für eine erfolgreiche Analyse ist jedoch ein lückenloses Signal. Wenn nun Datenlücken aufgetreten sind, wurden diese von den vorangegangenem und dem nachfolgendem Wert linear interpoliert um einen vollbesetzten Datenarray für die Ableitung der Parameter verwenden zu können.

4.1.4 Anwendung Savitzky-Golay Filterung

4.1.4.1 Polynom 2. Grades

Durch den Fakt, dass die MODIS Daten fehlerbehaftet sind, wird der Rohdatenwert durch einen gefilterten ersetzt. Um die verrauschte MODIS Zeitreihe für die später folgende relative radiometrische Kalibrierung zu filtern wurde die Methode nach Savitzky-Golay gewählt. Sie stammt aus der Signalverarbeitung und beschreibt einen Glättungsalgorithmus, der die Koeffizienten eines dem Datenmaterial zu Grunde liegend höheren Polynoms schätzt. Im Falle der Datenvorverarbeitung wurde ein Polynom 2. Grades gewählt,

$$f(t) = a_0 + a_1 \cdot t + a_2 \cdot t^2 \tag{4.29}$$

das sich auf Werte von 15 Epochen angleicht. Dieses Fenster bewegt sich nun über den ausgewählten Datenbereich und filtert die Daten anhand des ausgewählten Polynoms. Vorteile ergeben sich daraus, dass im Vergleich zu einem gleitenden Mittel die Spitzen nicht abgeschnitten werden sondern in die Charakteristik des Polynoms mit einfließen. Nachteil sind, das nicht identifizierte Ausreißer ebenfalls so mit in die Berechnung einfließen und Einfluss nehmen. Der Wert in der Mitte des sich über die Zeit bewegenden Fensters ist im Interessenmittelpunkt und wird als später zu verwendender Wert in ein neues Rasterfile geschrieben.

Die Anzahl der Datenwerte auf der linken Seite werden als n_L, sowie die Datenwerte auf der rechten Seite mit n_R beschrieben, wobei gilt $n_L = n_R$. Die Parameter für das Polynom 2. Grades M von i , $a_0 + a_1 i + \cdots + a_M i^M$ werden mittels der Methode Ausgleich nach Parametern für die Werte $l_{-n_L}, \ldots, l_{n_R}$ bestimmt. Die Designmatrix A setzte sich hierbei wie folgt

zusammen:

$$A_{ij} = i^j \quad i = -n_L, \ldots, n_R, \quad j = 0, \ldots, M \tag{4.30}$$

Der Normalgleichung ausgedrückt durch den Parametervektor $\widehat{\mathbf{x}}$ und dem Beobachtungsvektor l_i in Matrizenschreibweise lautet

$$\left(\mathbf{A}^T \cdot \mathbf{A}\right) \cdot \widehat{\mathbf{x}} = \mathbf{A}^T \cdot \mathbf{l} \qquad or \widehat{\mathbf{x}} = \left(\mathbf{A}^T \cdot \mathbf{A}\right)^{-1} \cdot \left(\mathbf{A}^T \cdot \mathbf{l}\right) \tag{4.31}$$

Anhand der Qualitätsinformation aus den MODIS-Epochen wird die Gewichtsmatrix P aufgestellt:

$$P_{ij} = \begin{bmatrix} p_{11} & 0 & \ldots \\ 0 & p_{22} & \ldots \\ \vdots & \vdots & \ddots \end{bmatrix} \tag{4.32}$$

Somit ergibt sich mit der Gewichtsmatrix folgende Form für die Normalgleichungen für den Parametervektor und den Beobachtungsvektor:

$$\left(\mathbf{A}^T \cdot \mathbf{P} \cdot \mathbf{A}\right) \cdot \widehat{\mathbf{x}} = \mathbf{A}^T \cdot \mathbf{P} \cdot \mathbf{l} \qquad or \qquad \widehat{\mathbf{x}} = \left(\mathbf{A}^T \cdot \mathbf{P} \cdot \mathbf{A}\right)^{-1} \cdot \left(\mathbf{A}^T \cdot \mathbf{P} \cdot \mathbf{l}\right) \tag{4.33}$$

Die ausgeglichenen, gefitteten Beobachtungen erhält man anhand von

$$\widehat{\mathbf{l}} = \mathbf{A} \cdot \widehat{\mathbf{x}} \tag{4.34}$$

Da die Qualitätsinformation der MODIS-Epochen nicht immer ganz der Richtigkeit entsprechen (Restwolkenpixel, Dunst etc) wird eine zweite Iteration durchgeführt und die Daten werden anhand des Verbesserungsvektors neu gewichtet:

$$v = -\left[\mathbf{I} - \mathbf{A} \cdot \left(\mathbf{A}^T \cdot \mathbf{P} \cdot \mathbf{A}\right)^{-1} \cdot \left(\mathbf{A}^T \cdot \mathbf{P}\right)\right] \cdot \mathbf{l} \tag{4.35}$$

$$dv = \frac{1}{v} \tag{4.36}$$

$$P = \mathbf{I} \cdot dv \tag{4.37}$$

4.1.4.2 Gapfilling

Da es jahreszeitenabhängig zu länger anhaltender Wolkenbedeckung und somit zu Datenlücken für die Schätzung der Parameter des Polynoms kommen kann wird anstatt des Polynoms eine Gerade verwendet. Wenn die Anzahl der Elemente linksseitig und rechtsseitig eine gewisse Mindestanzahl unterschreiten, zum Beispiel $n_L \leq 3$ und $n_r \leq 3$ so wird anstatt eines Polynom 2. Grades eine Gerade durch die Daten gelegt und der zentrale Wert der neuen Berechnung als neuer Pixelwert verwendet. Die Identifikation der zu kleinen Anzahl erfolgt durch vordefinierte Pythonroutinen.

$$f(t) = a_0 + a_1 \cdot t \tag{4.38}$$

Die linear zu fittenden Daten werden mittels einer Pythonroutine ermittelt und zu einem Array zusammengefügt. n_C repräsentiert hierbei den eigentlich zu fittenden Wert um jenen herum normal das Polynom 2. Grades gelegt wird.

$$l_{ids} = l[n_L \leq 3; n_C = 0; n_R \leq 3] \tag{4.39}$$

Die Designmatrix bezieht sich hierbei nur auf die speziellen Situationen und variiert in ihrer Zeilenanzahl. Sie ist in ihrer Spaltenanzahl auf die Geradengleichung angepasst. Die Gewichtsmatrix verwendet jene Gewichte die bereits in der zweiten Iteration berechnet wurden. Der Beobachtungsvektor weist die gleiche Zeilenanzahl wie die Designmatrix auf

$$\widehat{\mathbf{x}} = \left(\mathbf{A}^T \cdot \mathbf{P} \cdot \mathbf{A}\right)^{-1} \cdot \left(\mathbf{A}^T \cdot \mathbf{P} \cdot l_{ids}\right) \tag{4.40}$$

Ist der interpolierte Wert nun jedoch kleiner als das Minimum oder größer als das Maximum im Beobachtungsvektor so wird der jeweilige Maximum oder Minimumwert gesetzt.

4.1.4.3 Verspeicherung der Zeitreihe

Der Filtervorgang findet Bandweise statt. Die gefilterten Daten werden zuerst als GeoTIFF verspeichert und in einem Folgeschritt zu europaweiten Mosaicen zusammengefügt sowie epochenweise in Stacks verspeichert. Als Ergebnis liegt nun einen geglättetete, wolkenfreie Zeitreihe der MODIS-Sensoren für ganz Europa (ausgenommen Island) vor, welche zur radiometrischen Kalibrierung für Landsat5 und Landsat 7 Daten verwendet werden kann.

4.1.5 Ausreisserdetektion

Aussreissertests werden dazu benutzt um die Zuverlässigkeit von Daten zu überprüfen und vor allem extreme Erscheinungen in den Daten zu identifizieren und gegebenenfalls zu eliminieren. Ausreisser sind extrem hohe oder niedrige Werte in einer ansonst mäßig unterschiedlichen Messreihe. Im folgenden wird die Methode nach Grubbs beschrieben, welche in dieser Diplomarbeit Verwendung gefunden hat. Ziel der implementierten Ausreisserdedektion ist es vor der Aggregierung der LandsatDaten auf die MODIS-Pixel-Auflösung nicht ausmaskierte Wolkenpixel aufgrund der nicht perfekten Wolkenmaske des LEDAPS-Programmes zu identifizieren und zu eliminieren. Dies impliziert das nach extrem hohen Werten in den Daten gesucht wird.

Das Verfahren selbst prüft eine berechnete Testgröße G anhand des Mittelwert $\hat{x}$ und der Standardabweichung σ des Samples und prüft ob die Hypothese oder Gegenhypothese wahr ist, das es sich bei der Beobachtung um einen Aussreisser handelt.

$$G = \frac{max\,|x_i - \hat{x}|}{\sigma} \tag{4.41}$$

$$\alpha \qquad \ldots Signifikanzniveau \tag{4.42}$$

$$G > \frac{(N-1)}{\sqrt{N}} \sqrt{\frac{(t_{\alpha/(2N),N-2})^2}{N-2+(t_{\alpha/(2N),N-2})^2}} \tag{4.43}$$

Viele statistische Methoden werden durch das Vorhandensein von Aussreisern beeinflusst Bei schon simplen Berechnungen wie dem Mittelwert oder

der Standardabweichung kann es zu einer Strörung durch einen einzigen „verfälschten„ Wert kommen.

4.2 Verwendete Sprachen und Programme aus dem Bereich Data Science sowie Geoinformatik

4.2.1 Softwareentwicklung mit Python

Python ist wenn nicht die am meisten verwendete Sprache wenn es um Datenmanipulation geht. Sei es serverseitig im Backendbereich von Webservices oder Machine Learning Anwendungen, Python bietet so ziemlich zu jeder Problemstellung eine passende Herangehensweise oder Lösung. Die Community ist riesig und man findet sehr schnell Hilfe zu Problemstellungen in diversen Foren wie *www.stackoverflow.com*. Im Zuge dieser Diplomarbeit wurden zwei Versionen von Python verwendet (Python 3.8 und Python 2.7) um Datenmanipulationsschritte zu automatisieren. Der gesamte Prozess der Datenakquisition, Datenaufbereitung als auch jener der relativen Kalibrierung und Ergebnispräsentation ist entweder mit bereits vorhandenen Bibliotheken oder selbstgeschrieben Modulen in Python umgesetzt worden und umfasst einige tausende Zeilen Code. Die von mir verwendete IDE zur Erstellung der Skripts und Software stammen von Jetbrains und Microsoft und ist unter den Namen PyCharm sowie Visual Stuio Code sehr bekannt. Hier sei darauf hingewiesen, dass das Thema dieser Diplomarbeit sich nicht im Detail mit Problemstellungen aus der Softwareentwicklung auseinandersetzt, sondern die Softwareentwicklung mit Python als Mittel zum Zweck verwendet. Nichts destotrotz sind ein paar verwendete Feinheiten beschrieben, die einen Geschwindigkeitsvorteil in der Berechnung oder bei der Manipulation der Daten gebracht haben.

4.2.1.1 Python 3.8

Python 3.8 war das Mittel zum Zweck für so ziemlich alle Arbeitsschritte um bis einschliesslich zur gefiltereten MODIS-Zeitreihe zu gelangen. Die MODIS Daten wurden mittels einem Webscrabber-Script unter Verwendung von *bs4* und dem Pythoninternen *requests* Modul von den NASA Servern gedownloaded, mittels *GDAL* vom HDF5-Format in einzelne, bandweise GEOTIFFS konvertiert und anschliessend mittels *numpy* und den vorhin beschrieben Algorithmen gefiltert oder rekonstruiert. Diese gefilterten Daten wurden weiters zu epochenweisen Stacks verarbeitet, da die relative Kalibration diese voraussetzt.

4.2.1.2 Python 3.8 - Multiprocessing

Da nur die gedownloadeten HDFS und rohen GEOTIFF Daten alleine fast einen ganzen Terabyte an Speicherplatz benötigen, war klar das es nicht sinnvoll sein kann, einem einzigen Pythonprozess die ganze Arbeit machen zu lassen. Multithreading ist am Papier mit Python möglich, aber auf Grund des Global Interpreter Locks immer an eine CPU gebunden. Paralleles Ausführen von Arbeitsschritten auf meherern CPUs ist aber mittels dem in Python integrierten Multiprocessing Modul und seit der Python Version 3.8 auch mit einem Shared Memory oder gemeinsamen Arbeitsspeicherbereich möglich. Dies erlaubt einen Speicherbereich zwischen mehreren Python Prozessen zu teilen bzw zugreifbar zu machen, um große Datenmengen parallel zu verarbeiten. Jedoch sei hier darauf hingewiesen, dass man bei der Verwendung von Shared-Memory-Objekten sich nicht mehr auf die gewohnte Typesicherheit von Python verlassen darf und zusätzlich bedenken muss:

- welchen Typ hat das Shared-Memory-Objekt: -z.B. int16
- welcher Typ kommt bei der Berechnung heraus - z.B. float64
- in welchen Typ muss ich das Ergebnis wieder umwandeln um es am Shared-Memory-Object zu verspeichern

Wenn man dies nicht berücksichtigt kann dies es zu unerwartetem Verhalten führen und in elendslange Fehlersuche münden. Behirnt man dies jedoch korrekt, ist echtes paralleles Programmieren mit Python für CPU intensive Rechenoperationen vollumfänglich möglich.

4.2.1.3 Python 2.7

Die Rechenschritte der relativen Kalibration wurden alle in Python 2.7 getätigt. Grund waren die anfänglich verwendeten Module der arcpy API von ESRI, welche jedoch oft erhebliche Performanceprobleme hatten und im Endeffekt alle durch selbstgeschriebene Module oder durch Verwendung von bekannten Open Source Bibliotheken wie GDAL, numpy oder scipy ersetzt wurden.

4.2.1.4 Anaconda

Um zwischen den Interpreterversionen ohne Probleme hin und her wechseln zu können, wurde der Package und Virtual-Environment Manager Anaconda verwendet. PyCharm unterstützt auch unterschiedliche Interpreter die man sich als extra Runtime-Konfiguration in seinem Projekt erstellen kann.

4.2.2 ArcGIS, QGIS

Die abgeleiteten Daten benötigen natürlich eine menschliche, visuelle Kontrolle. Dies geschah in erster Linie mit ESRI's ArcMap 10.2 oder QGis 3.16. Wie schon vorhin erwähnt, wurde anfangs auch Skripts oder Toolboxen von ArcMap verwendet, jedoch durch eigene Softwaremodule ersetzt. Besonders nützlich war in beiden Programmen der Information Cursor, welcher erlaubt einzelne Pixel-Zeitreihen auf schnelle Art und Weise tabellarisch zu visualisieren und zu vergleichen.

4.2.3 Betriebsysteme, Speicherplatz und Rechenlogistik

Hier möchte ich nur kurz Anreißen, dass die großen Datenmengen eine eigene Denkweise, Infrastruktur und Logistik erfordert haben. Die verwendeten Betriebssysteme unterscheiden sich erheblich in den Ausführzeiten der Python Programme welche für das Rekonstruieren der MODIS Zeitreihen verwendet wurden. Deshalb wurde beim Fitten und Filtern der Daten auf Linux (Debian 10, Ubuntu 18.04) vertraut. Es kamen bis zu vier Rechner mit mindestens 4 CPUs ab 3GHz Takt und mindestens 32GB RAM zum Einsatz um die Daten parallel zu verarbeiten. Pro Spektralband der MODIS Zeitreihe kann man für 20 Jahre und jeden 9ten Tag eine vorhandene Szene (oder 927 Datenpunkte) ca 17h Rechenzeit für Savitzky-Golay-Filter einplanen, die FFT brauchte hingegen nur an die drei Stunden. Der verbrauchte Speicherplatz für die MODIS Daten in der Version 6 sowie der Landsat Daten in roher als auch absolut Kalibrierter Form belaufen sich auf 2,42 TB (Terabyte). Um die Daten zu sichern wurde Speicherplatz im Gesamt Volumen von 11 TB angeschafft um sie auf drei unabhängigen Speichervolumen zu sichern.

Kapitel 5

Durchführung

5.1 Rekonstruktion und Filtern der Verrauschten MODIS V6 Zeitreihe

Die Daten der MODIS Zeitreihe liegen mit einer Qualitätsinformation wie schon in Kapitel 3.3.3.2 beschrieben vor. Zu jedem Zeitpunkt bzw zu jedem Pixel ist nun eine Qualitätsinformation vorhanden die in der P-Matrix der Ausgleichsfunktion als Gewichtung an die Beobachtungen angebracht wird. Um einen vielfältigen Vergleich zu erhalten, welche Gewichtung die besten Resultate liefert, oder eventuell welche Tradeoffs in Kauf genommen werden müssen, wurden mehrere Iterationen der SG Filterungen mit unterschiedlicher Gewichtung vorgenommen (dies kostet einiges an Speicherplatz!). Auch die Berechnungen der DFT wurde mit unterschiedlichen Gewichten durchgeführt, aber immer mit einer harmonischen Schwingung die auf 3 Elemente (hat sich als als am Idealsten herausgestellt) beschränkt war. Allein die Rekonstruktion und Filterung der FFT kommt gänzlich ohne Gewichtung aus. Zu Beginn eines Jahres liegen für gewöhnlich Daten mit schlechter räumliche und temporaler Abdeckung vor, da dies vor allem mit der vermehrten Wolkenbedeckung rückzuschließen ist, siehe Abbildung **??** und Abbildung **??**.

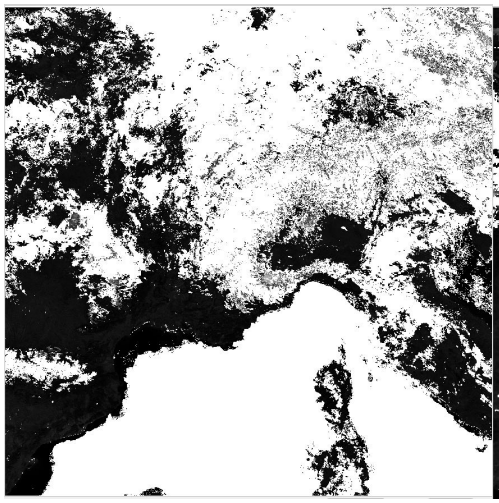


Abbildung 5.1: *Bildinformation für die Kachel h18v04 für den DOY 001 des Jahres 2001 - Weiss : NoData - Graustufen: Reflexionswerte*

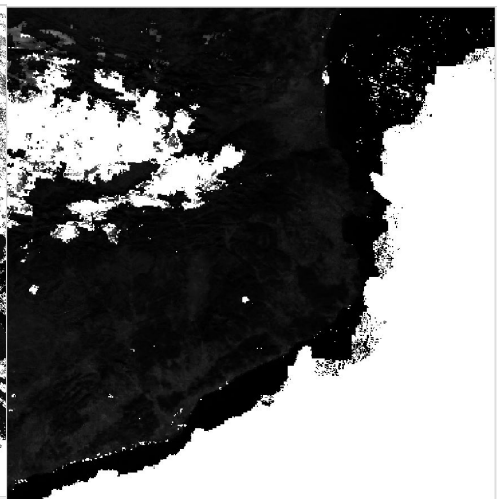


Abbildung 5.2: *Bildinformation für die Kachel h18v04 für den DOY 001 des Jahres 2001 - Weiss : NoData - Graustufen: Reflexionswerte*

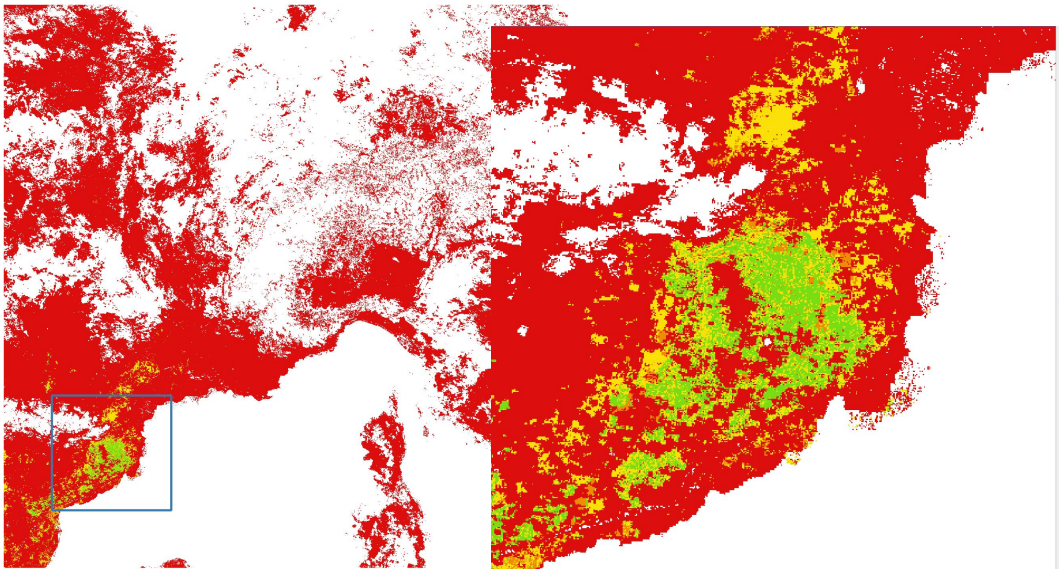


Abbildung 5.3: *Qualitätsinformtion für die Kachel h18v04 für den DOY 001 des Jahres 2001 - grün: full inversion - gelb: full inversion - orange: magnitude inversion (numobs >=7) - red: magnitude inversion (numobs 2 >=7) - white: NoData*

Abbildung 5.4: *Qualitätsinformtion für einen Auschnitt aus der Kachel h18v04 für den DOY 001 des Jahres 2001 - grün: full inversion - gelb: full inversion - orange: magnitude inversion (numobs >=7) - red: magnitude inversion (numobs 2 >=7) - white: NoData*

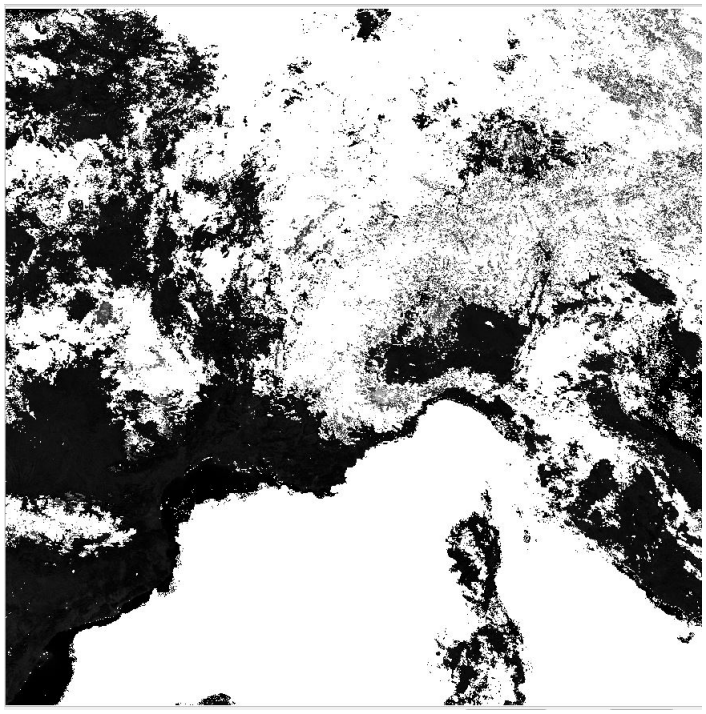


Abbildung 5.5: *Bildinformation für die Kachel h18v04 für den DOY 001 des Jahres 2001 - Weiss : NoData - Graustufen: Reflexionswerte*

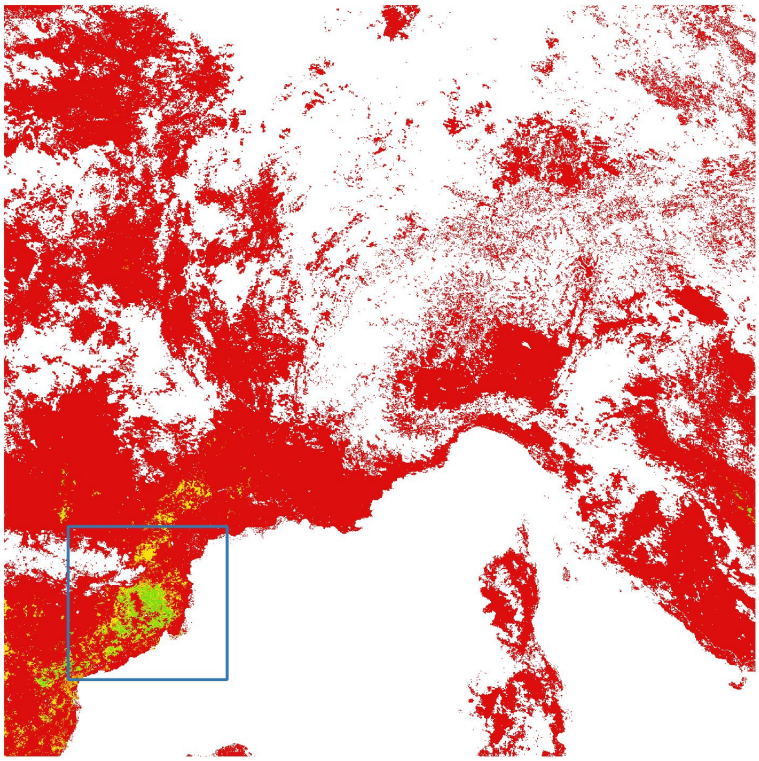


Abbildung 5.6: *Qualitätsinformtion für die Kachel h18v04 für den DOY 001 des Jahres 2001*

5.1.1 Savitzky-Golay Filterung mit einem Polynom 2. Grades

Wie schon in den Grundlagen angesprochen, verwendet eine Rekonstruktionsmethode den Savitzky-Golay-Filter um einerseits verrauschte Daten zu glätten als auch nicht vorhandene Daten zu rekonstruieren. Man wählt ein passendes sich bewegendes Zeitfenster aus, in diesem Fall werden 15 Beobachtungsepochen im Abstand von jeweils 8 Tagen verwendet, und updated dieses mit der nächsten Epoche nach abgeschlossener Filterung. Der zentrale Wert (nicht der Median) innerhalb dieses Datenarrays ist der gefilterte Wert, welcher von Interesse ist und zur weiteren Bearbeitung und Verspeicherung herangezogen wird. Bevor es jedoch ans glätten der Zeitreihe geht wird überprüft, ob es NaN stellen im SG-Fenster gibt. Füllwerte treten abhängig vom Fortschritt des Jahres vermehrt in den niederschlagsreichen Zeiten, besonders gegen Ende und Anfang des Jahres auf. Auch der

Rest des Jahres ist nicht davor gefeit keine NaN Werte zwischenzeitlich aufzuweisen. An diesen Stellen wird zu aller erst linear interpoliert, um einen Näherungswert für die anschließende Filterung an nicht besetzten Stellen zu haben.

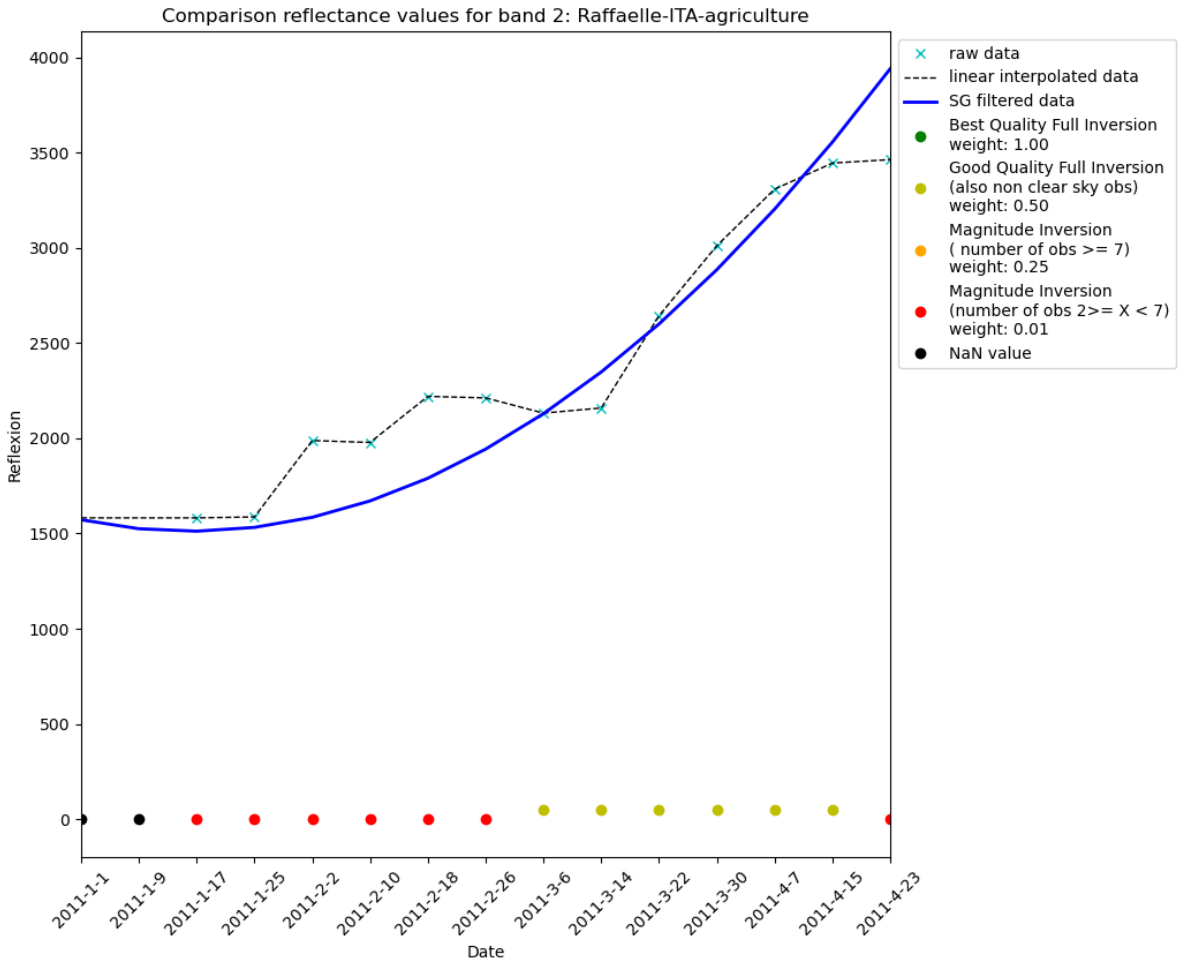


Abbildung 5.7: *Gegenüberstellung Rohdaten, lineare Interpolation, SG Filterung für einen Zeitraum von 15 Epochen im Raum Raffaelle Italien im NIR*

Abbildung 5.7 stellt diese unterschiedlichen Zustände des Datenmaterials grafisch dar. Die unbearbeiteten Rohdaten sind als cyanfarbige X-Signaturen

gekennzeichnet und deren Qualitätsklasse ist als farbige Punktsignatur am Fusse des Plotes dargestellt. Beste Qualität wird mit grün symbolisiert (in 5.7 ist keine vorhanden), gelb symbolisiert gute Qualität, sprich volle Inversion aber auch bewölkte Szenen werden mitverwendet, orange beschreibt, dass mindestens 7 Beobachtungen für die Wertermittlung vorgelegen sind, rot das mindestens zwei Beobachtungen aber maximal 7 Beobachtungen zur Wertermittlung herangezogen wurden. Schwarz sind NoData Werte welche nicht zur Berechnung herangezogen werden können. Diese NoData Stellen werden mittels einer linearen Interpolation aus dem vorangegangenem und nachfolgendem Wert approximiert, um einen Näherungswert für die Filterung nach SG zur Verfügung zu haben. In Abbildung 5.7 wird diese Approximation mittels der schwarzen gestrichelten Linie dargestellt. Dies ist nun die vollbesetzte Zeitreihe die zur Schätzung der Parameter des Polynom zweiten Grades wie in Formel 4.29, welches für den Savitzky-Golay-Filter verwendet, herangezogen wird. Die durchgezeichnete blaue Linie symbolisiert die gefilterte Zeitreihe unter Verwendung des SG Filters mit einem 15 tägigem Beobachtungsfenster. Die Beobachtungen wurden nach absteigender Qualität mit gewichtet und so in die P Matrix aus 4.32 übernommen.

- Best Quality = 1
- Good Quality = 0.5
- Magnitude Inversion (number of obs >= 7) = 0.25
- Magnitude Inversion (number of obs 2>= X < 7) = 0.01

Eine weitere Gewichtungskombination, bei der die beste Qualitätsgüte hoch, die Zweitbeste höher gewichtet und alle anderen Güteklassen sehr gering gewichtet sind, lässt den Filteralgorithmus sich mehr den Rohdaten annähern, welches hier in Abbildung 5.8 wieder für Raffaelle in Italien dargestellt ist.

- Best Quality = 1
- Good Quality = 0.5
- Magnitude Inversion (number of obs >= 7) = 0.01
- Magnitude Inversion (number of obs 2>= X < 7) = 0.0100000

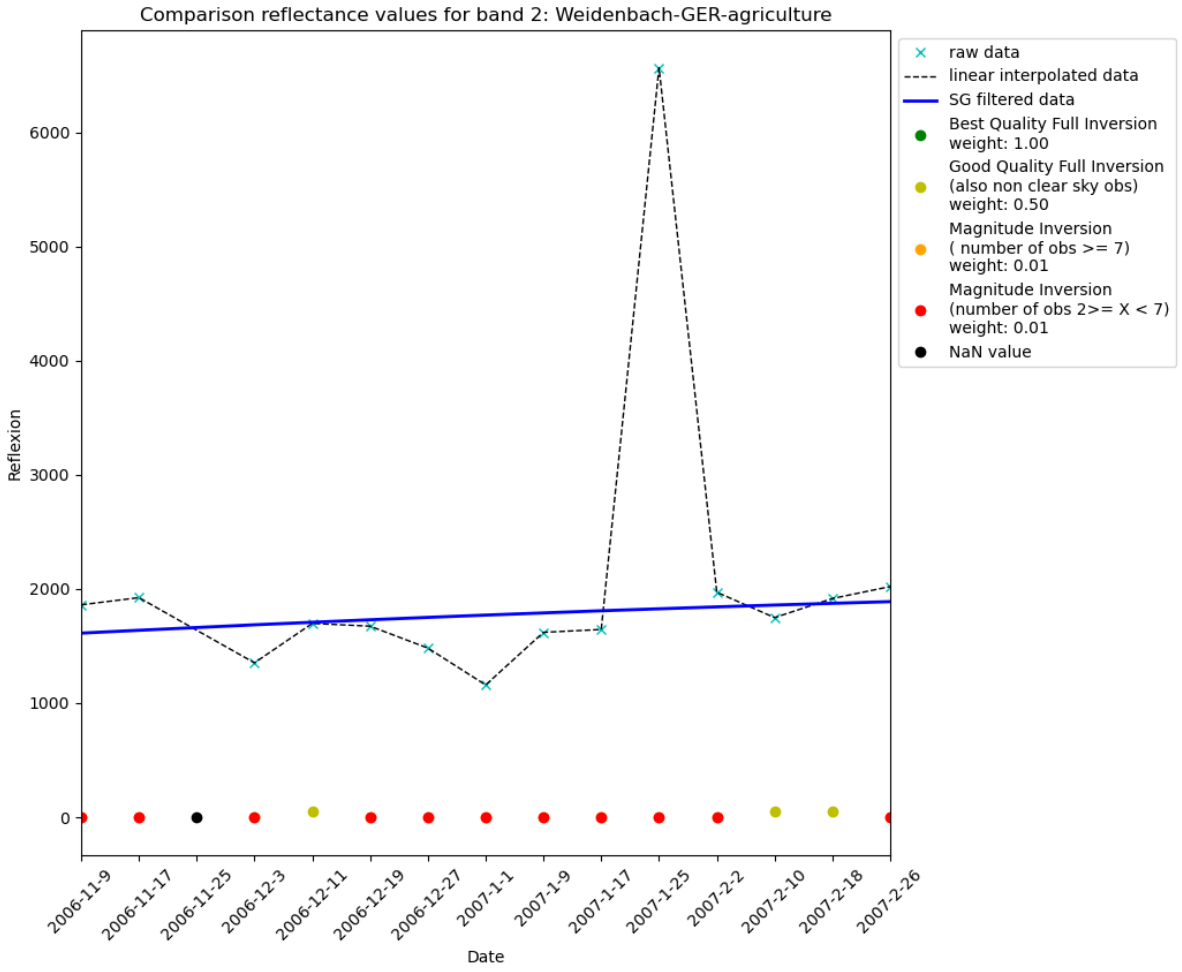


Abbildung 5.8: *Gegenüberstellung Rohdaten, lineare Interpolation undFMO-DIS SG Filterung für einen Zeitraum von 15 Epochen im Raum Weidenbach Deutschland im NIR mit einer niedrigen Gewichtung für alle ausser der besten und zweitbesten Qualitätstufe*

Eine weitere Iteration in Abbildung 5.9, bei der alle Güteklassen bis auf die Beste niedrig gewichtet sind, bring für diesen Fall nahezu keine Veränderung in diesem Zeitfenster .

- Best Quality = 1

- Good Quality = 0.01
- Magnitude Inversion (number of obs >= 7) = 0.01
- Magnitude Inversion (number of obs 2>= X < 7) = 0.01

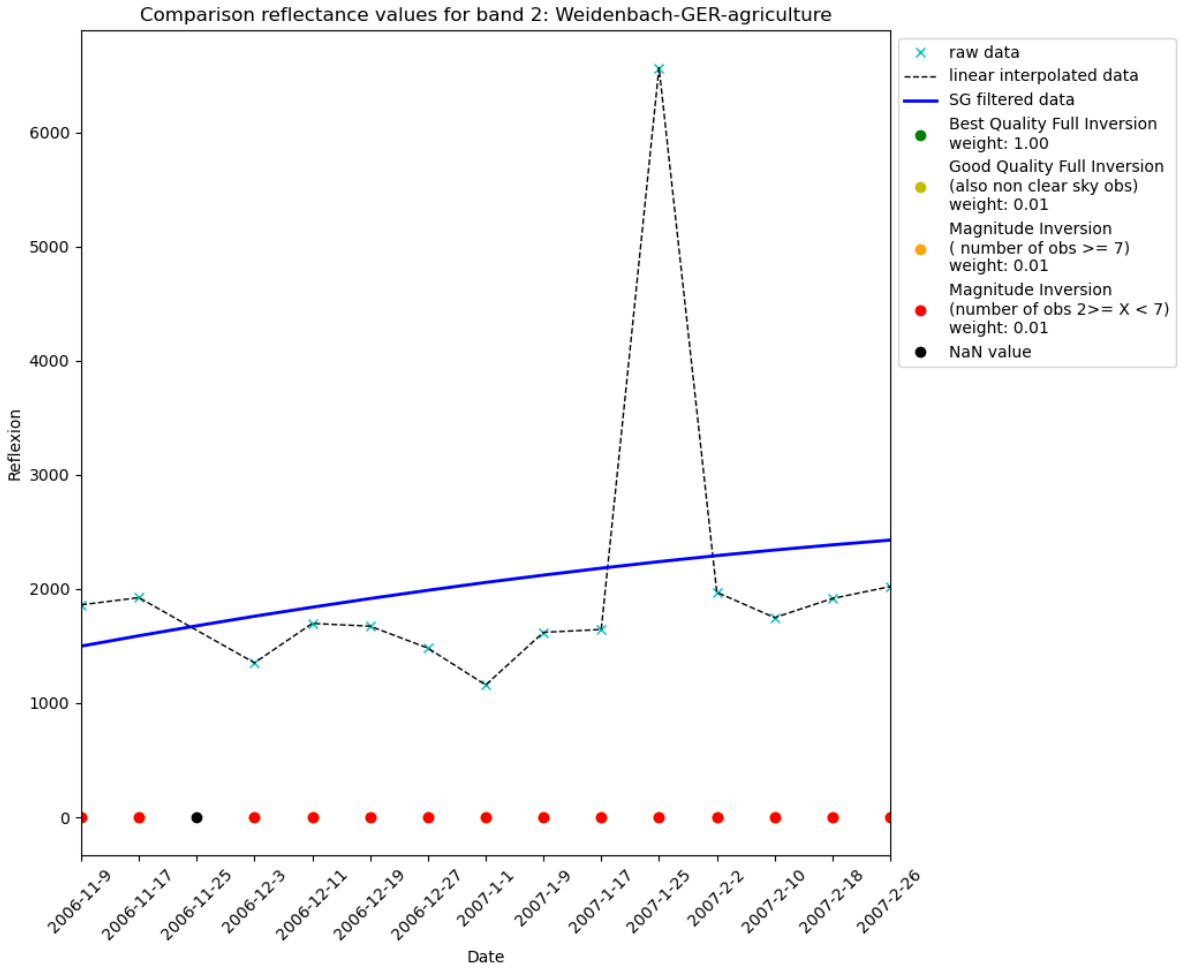


Abbildung 5.9: *Gegenüberstellung Rohdaten, lineare Interpolation, SG Filterung für einen Zeitraum von 15 Epochen im Raum Weidenbach Deutschland im NIR mit einer niedrigen Gewichtung für alle ausser der besten Qualitätsstufe (die hier aber nicht enthalten ist)*

Die Gegenüberstellung der errechneten Ergebnisse für die unterschiedlichen Gewichtungen sind in Grafik 5.10 veranschaulicht. Sie zeigt hierbei das Ergebnis für einen Pixel entsprechen Nähe Weidenbach in Deutschland in einem landwirtschaftlich genutztem Gebiet. Die Datenpunkten mit der cyanfärbigen Sternsignatur sind die Rohdatenpunkte, die schwarz strichlierte Linie stellt die Rohdaten mit linear interpolierten Daten für Datenlücken dar und die färbig durchgezogenen Linien stellen die rekonstruierten Daten für das Jahr 2002 dar. Blau stellt jene Ergebnisse dar die mit einer Gewichtsmatrix gerechnet wurden, die 4 unterschiedlichen Gewichten ausgestattet sein kann. Der gelbgefärbte Graf gewichtet nur die besten 2 Datenqualitätsklassen hoh, jene Pixel mit schlechterer Qualität niedrig. Grün symbolisiert eine sehr konservative Gewichtung, bei welcher nur die beste Pixelqualität auch hoch gewichtet wird, alles andere wird mit einem niedrigen Gewicht ausgestattet.

Zu Beginn und zum Ende der Graphen existieren oft über ein, zwei Epochen weg höhere Werte, welche den Graphen einen Sprung nach oben erleben lassen. Dies dürfte auf bekannte Probleme des Sensors im Jahr 2002 zurück zuführen sein. Die Datenrekonstruktion läuft so weit ganz ordentlich wie auch die Beispiele für Bad Pippoldsau im deutschen Schwarzwald 5.11 und ein Waldgebiet in Doba Lothringen Frankreich 5.12 . Jedoch wurde ein Problem bei Wasserflächen ausgemacht. Wenn nicht genug Beobachtungen vorliegen und die interpolierten Werte bei Null liegen, kommt es zu singulären Matrizen und der Ausgleich liefert keine brauchbaren Ergenisse wie Abbildung 5.13 veranschaulicht. Um dieses Problem zu umgehen werden an solchen Positionen linear interpolierte Werte zwischen den einzelnen Stützstellen herangezogen. Diese Werte werden ja noch vorab dem Ausgleich an jenen Stellen ermittelt, die einen NaN Wert beinhalten, bleiben als Kopie im Speicher erhalten und können somit sehr schnell und leicht bei der Hand zu haben.

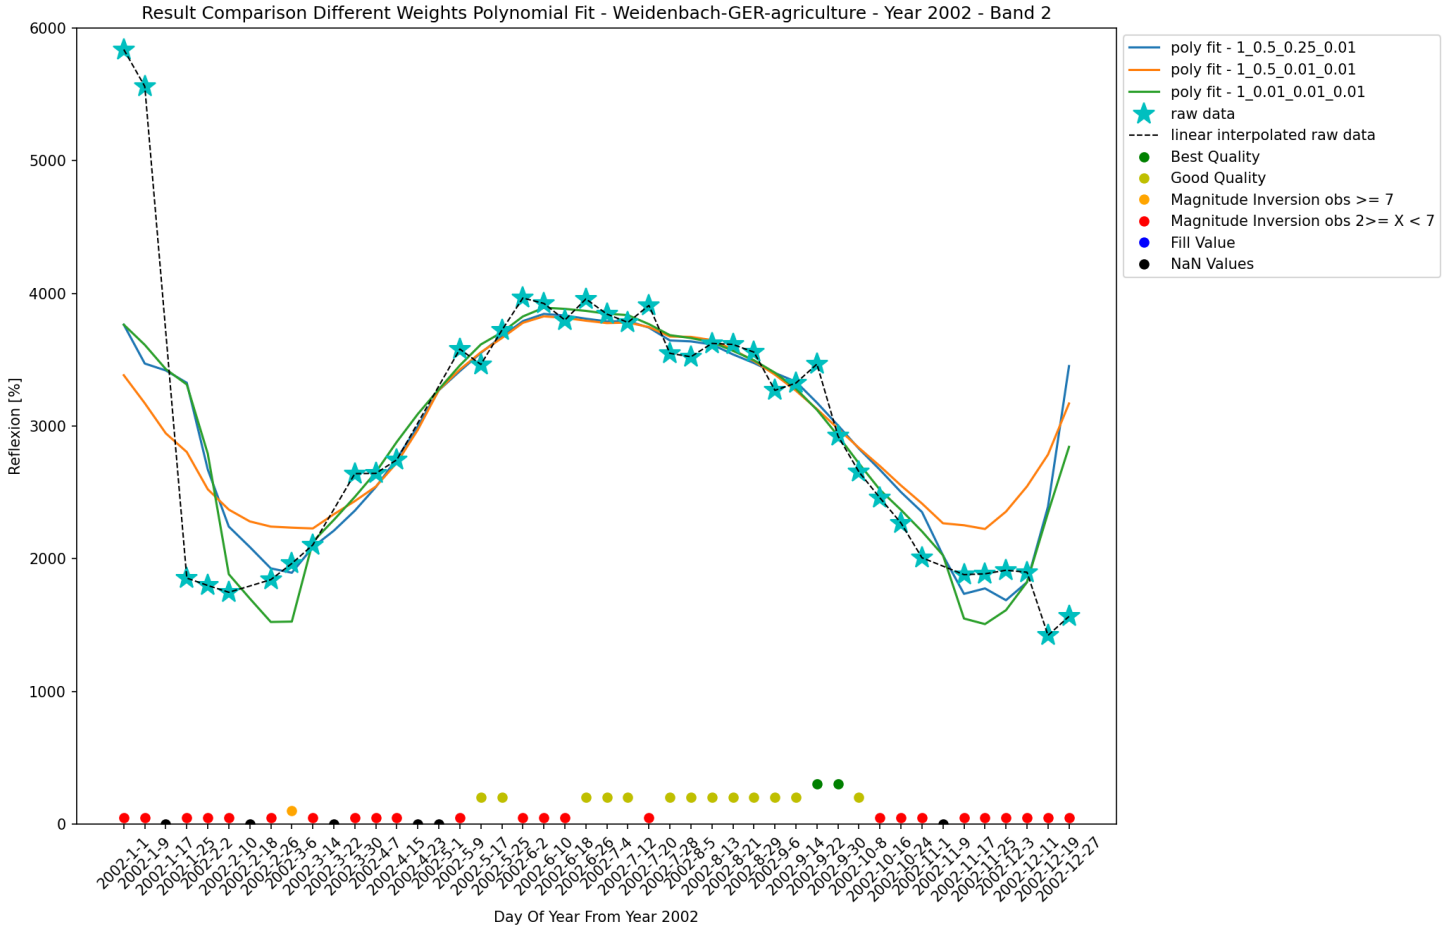


Abbildung 5.10: *Vergleich der rekonstruierten Zeitreihe für das Jahr 2002 im Bereich Weidenbach Deutschland unter Verwendung unterschiedlicher Gewichtung für die 4 Pixelqualitätsstufen*

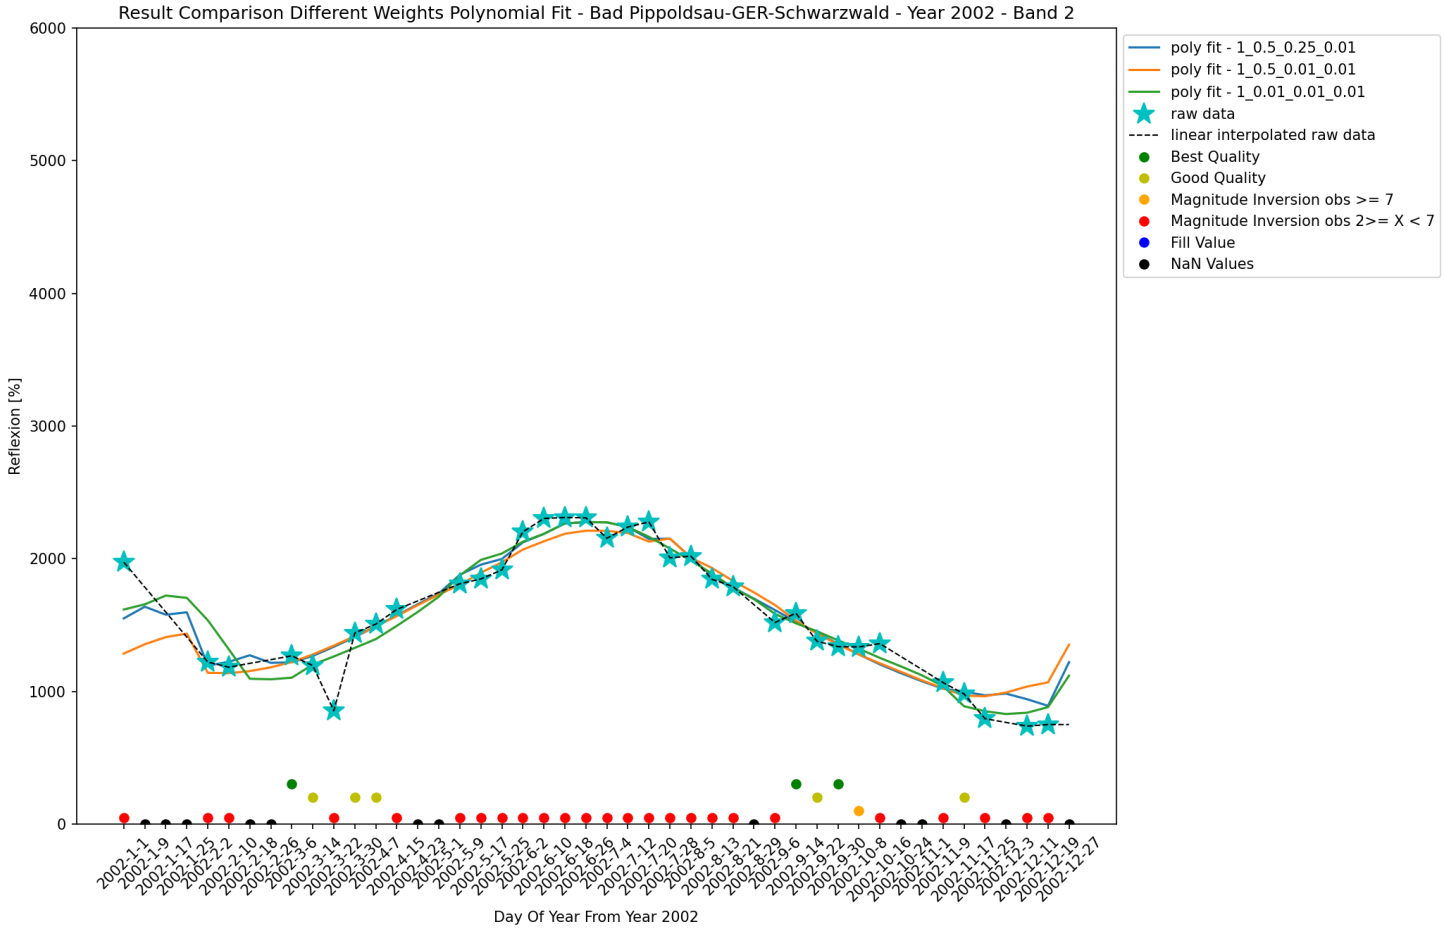


Abbildung 5.11: *Vergleich der rekonstruierten Zeitreihe für das Jahr 2002 im Bereich Bad Pippoldsau Deutschland unter Verwendung unterschiedlicher Gewichtung für die 4 Pixelqualitätsstufen*

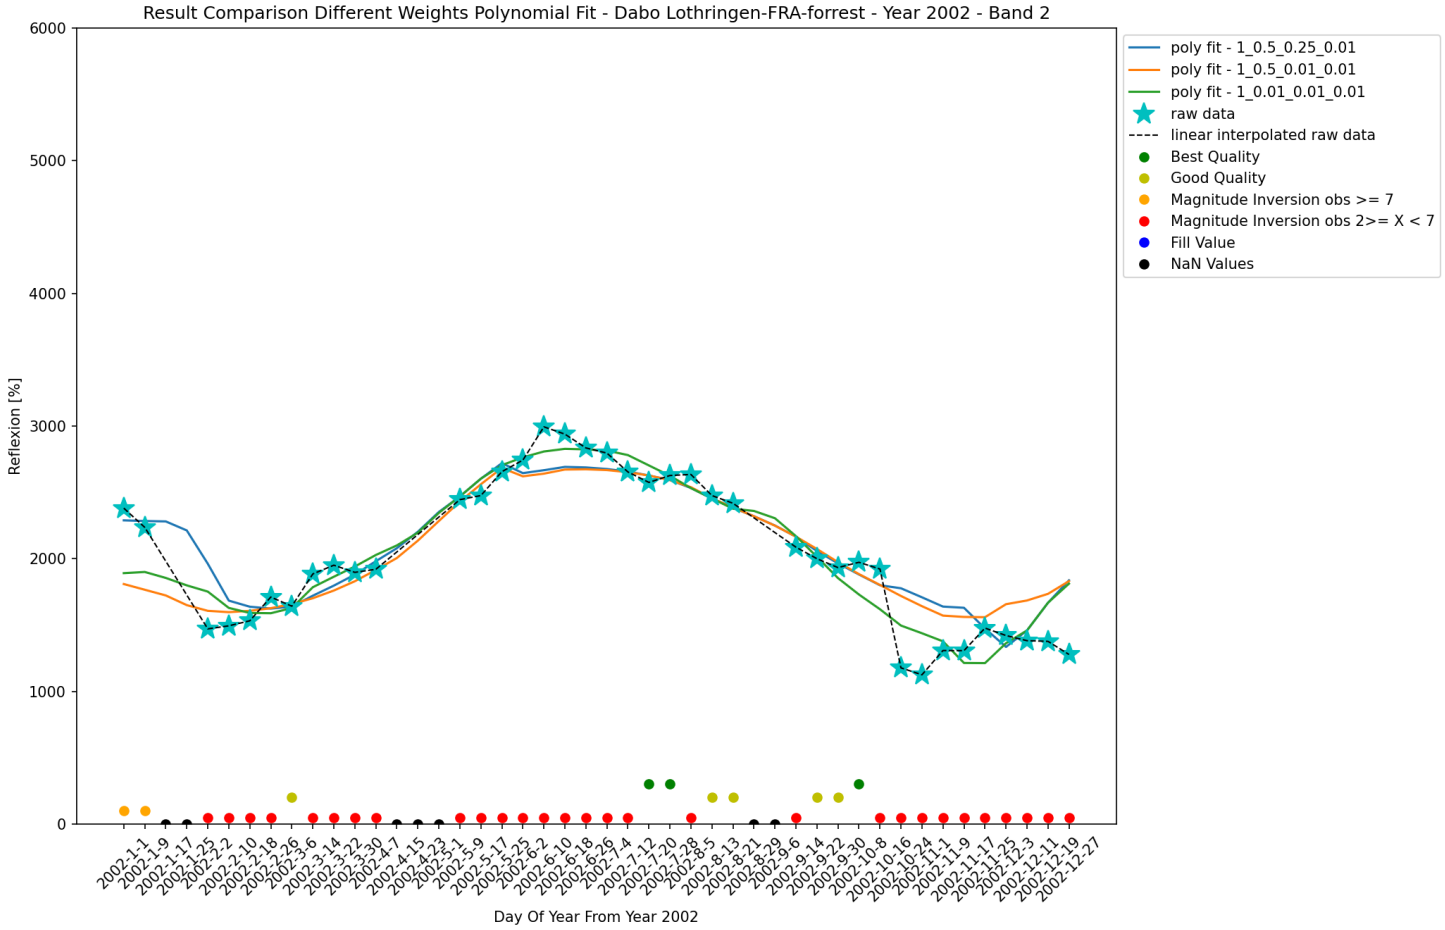


Abbildung 5.12: *Vergleich der rekonstruierten Zeitreihe für das Jahr 2002 im Bereich Doba Lothringen Frankreich unter Verwendung unterschiedlicher Gewichtung für die 4 Pixelqualitätsstufen*

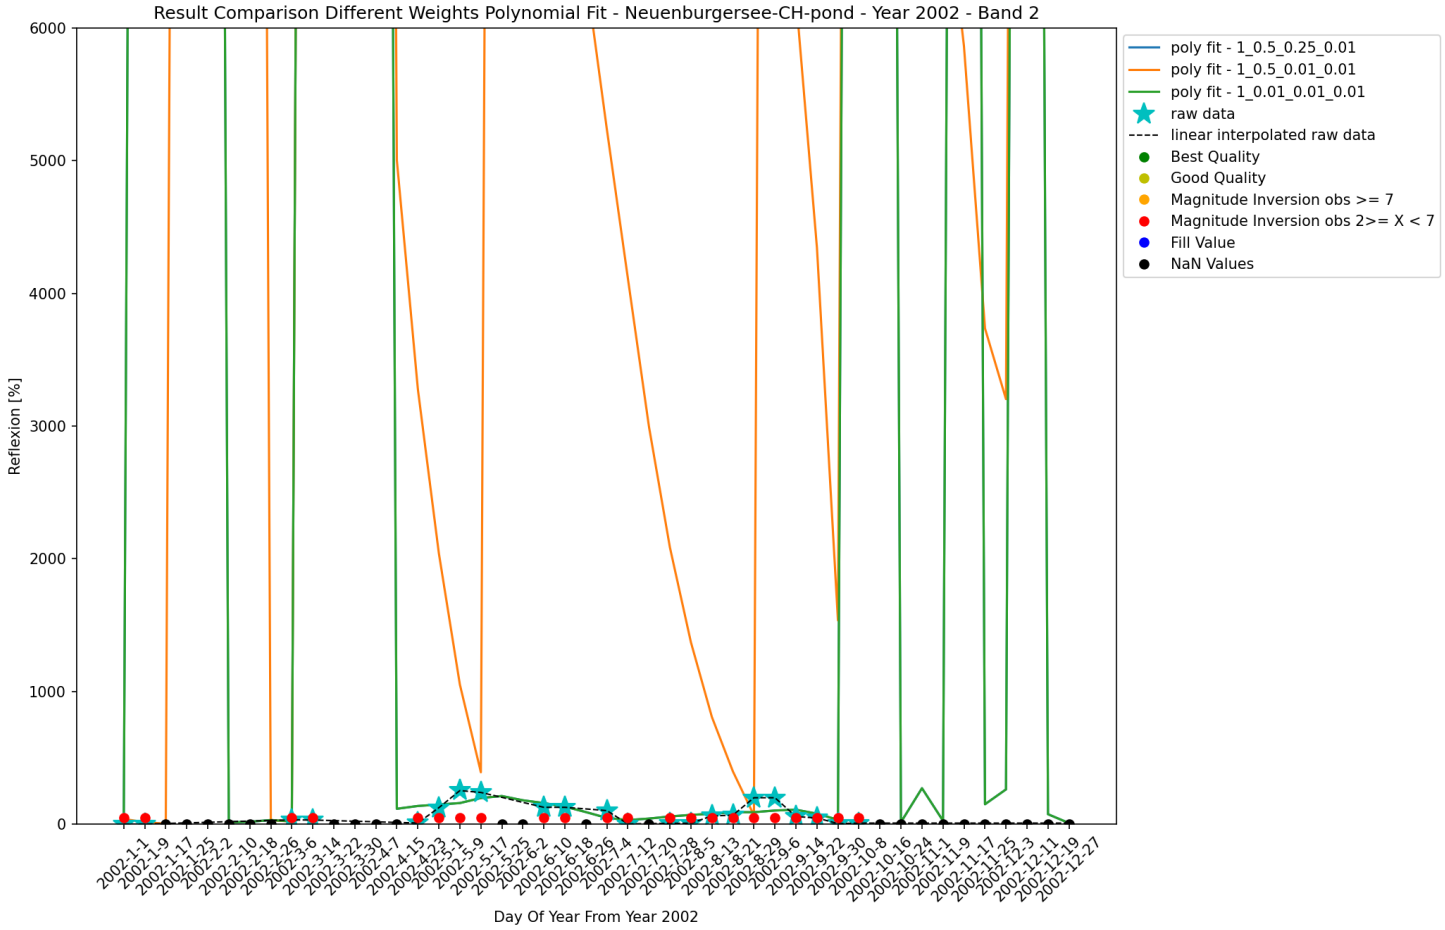


Abbildung 5.13: *Vergleich der rekonstruierten Zeitreihe für das Jahr 2002 im Wasserbereich des Neuenburgersees in der Schweiz unter Verwendung unterschiedlicher Gewichtung für die 4 Pixelqualitätsstufen*

5.1.2 DFT

5.1.3 FFT

Kapitel 6

Literaturverzeichnis

Atkinson, P. M., Jeganathan, C., & Dash, J. (2009). Analysing the effect of different geocomputational techniques on estimating phenology in India. In B. G. Lees, & S.W. Laffan (Eds.), *10th International Conference on GeoComputation*. Sydney: UNSW.

Atkinson, P. M., Jeganathan, C., Dash, J., & Atzberger, C. (2012). Intercomparison of four models for smoothing satellite sensor time-series data to estimate vegetation phenology. *Remote Sensing of Environment, 123*, 400–417. https://doi.org/10.1016/j.rse.2012.04.001

Bradley, B. A., Jacob, R. W., Hermance, J. F., & Mustard, J. F. (2007). A curve fitting procedure to derive inter-annual phenologies from time series of noisy satellite NDVI data. *Remote Sensing of Environment, 106*(2), 137–145. https://doi.org/10.1016/j.rse.2006.08.002

Chen, J., Jönsson, P., Tamura, M., Gu, Z., Matsushita, B., & Eklundh, L. (2004). A simple method for reconstructing a high-quality NDVI time-series data set based on the Savitzky–Golay filter. *Remote Sensing of Environment, 91*(3-4), 332–344.

de Beurs, K. M., & Henebry, G. M. (2010). Spatio-temporal statistical methods for modelling land surface phenology. In I. L. Hudson, & M. R. Keatley (Eds.), *Phenological research*. Springer Science + Business Media. https://doi.org/10.1007/978-90-481-3335-2_9

Eklundh, L., & Jönsson, P. (2012). *TIMESAT 3.1 software manual*. Lund University & Malmö University. http://www.nateko.lu.se/TIMESAT/

Eklundh, L., & Jönsson, P. (2015). *TIMESAT 3.2 with parallel processing Software Manual*. Lund and Malmö University, Sweden.

Gao, F., Morisette, J. T., Wolfe, R. E., Ederer, G., Pedelty, J., Masuoka, E., Myneni, R., Tan, B., & Nightingale, J. (2008). An Algorithm to Produce Temporally and Spatially Continuous MODIS-LAI Time Series. *IEEE Geoscience and Remote Sensing Letters, 5*(1), 60–64.

Hermance, J. F., Jacob, R. W., Bradley, B. A., & Mustard, J. F. (2007). Extracting Phenological Signals From Multiyear AVHRR NDVI Time Series: Framework for Applying High-Order Annual Splines With Roughness Damping *IEEE Transactions on Geoscience and Remote Sensing, 45*(10), 3264–3276.

Helder, D., Thome, K. J., Mishra, N., Chander, G., Xiong, X., Angal, A., & Choi, T. (2013). Absolute radiometric calibration of Landsat using a pseudo invariant calibration site. *IEEE Transactions on Geoscience and Remote Sensing, 51*(3), 1360–1369. https://doi.org/10.1109/TGRS.2013.2243738

Jönsson, P., & Eklundh, L. (2004). TIMESAT—a program for analyzing time-series of satellite sensor data. *Computers & Geosciences, 30*(8), 833–845. https://doi.org/10.1016/j.cageo.2004.05.006

Lu, X., Liu, R., Liu, J., & Liang, S. (2007). Removal of Noise by Wavelet Method to Generate High Quality Temporal Data of Terrestrial MODIS Products. *Photogrammetric Engineering & Remote Sensing, 73*(10), 1129–1139.

Markham, B. L., Barker, J. L., Barsi, J. A., Kaita, E., Thome, K. J., Helder, D. L., Palluconi, F. D., Schott, J. R., & Scaramuzza, P. (2003). Landsat-7 ETM+ radiometric stability and absolute calibration. *Proceedings of SPIE*, 4881, 308–318. https://doi.org/10.1117/12.462410

Press, W. H., Teukolsky, S. A., Vetterling, W. T., & Flannery, B. P. (1992). *Numerical recipes in C: The art of scientific computing* (2nd ed.). Cambridge University Press.

Román, M. O., Schaaf, C. B., Woodcock, C. E., Strahler, A. H., Yang, X., Braswell, R. H., Curtis, P. S., Davis, K. J., Dragoni, D., Goulden, M. L., Gu, L., Hollinger, D. Y., Kolb, T. E., Meyers, T. P., Munger, J. W., Privette, J. L., Richardson, A. D., Wilson, T. B., & Wofsy, S. C. (2009). The MODIS (Collection V005) BRDF/albedo product: Assessment of spatial representativeness over forested landscapes. *Remote Sensing of Environment, 113*(11), 2476–2498. https://doi.org/10.1016/j.rse.2009.07.009

Tan, B., Morisette, J. T., Wolfe, R. E., Gao, F., Ederer, G. A., Nightingale, J., & Pedelty, J. A. (2011). An enhanced TIMESAT algorithm

for estimating vegetation phenology metrics from MODIS data. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 4*(2), 361–371. https://doi.org/10.1109/JSTARS.2010.2075916

Technische Universität Graz. (2021). *Chapter 7a: Data preprocessing* [Vorlesungsfolien]. Vorlesung Environmental Monitoring with Remote Sensing, Institut für Geodäsie, Technische Universität Graz.

Tokola, T., Löfman, S., & Erkkilä, A. (1999). Relative calibration of multitemporal Landsat data for forest cover change detection. *Remote Sensing of Environment, 68*(1), 1–11. https://doi.org/10.1016/S0034-4257(98)00096-0

U.S. Geological Survey. (2013). *Landsat Ecosystem Disturbance Adaptive Processing System (LEDAPS) algorithm description* (Open-File Report 2013–1057). U.S. Department of the Interior. https://doi.org/10.3133/ofr20131057

Vermote, E., Tanré, D., Deuzé, J. L., Herman, M., Morcrette, J.-J., & Kotchenova, S. Y. (2006). *Second simulation of a satellite signal in the solar spectrum – Vector (6SV)* (6S User Guide, Version 3).

Vermote, E. F., & Saleous, N. Z. (2006). Calibration of NOAA16 AVHRR over a desert site using MODIS data. *Remote Sensing of Environment, 105*(3), 214–220. https://doi.org/10.1016/j.rse.2006.06.015